第 37 卷 第 3 期
2024 年 3 月

中 国 公 路 学 报
China J. Highw. Transp.

Vol. 37 No. 3
Mar. 2024

文章编号:1001-7372(2024)03-0134-13

智能网联车辆加速车道类人化汇入控制研究

谷梦路[1],葛振振[1],王 畅*[1,2],苏彦奇[1],郭应时[1]

(1. 长安大学 汽车学院,陕西 西安 710064; 2. 长安大学 汽车运输安全保障技术交通行业重点实验室,陕西 西安 710064)

摘要:为研究智能网联车辆(Intelligent Connected Vehicle, ICV)与高速公路主线传统人工驾驶车辆(Human-driven Vehicle, HDV)交互时通过高速公路加速车道的汇入控制算法,提出了一种融合随机森林(Random Forest, RF)算法和深度 Q 网络(Deep Q-network, DQN)算法的 ICV 汇入控制模型(DQN-RF)。首先,建立路侧数据采集平台,采集了中国 G70 高速公路加速车道汇入区域 HDV 的真实汇入过程数据。其次,考虑汇入环境车辆历史数据流和汇入车在加速车道的汇入紧迫度,建立了基于 RF 算法的类人化汇入决策模型。采用城市交通仿真(Simulation of Urban Mobility, SUMO)平台搭建了高速公路加速车道 ICV 汇入场景,并基于 Python 语言建立了 ICV 汇入控制深度强化学习测试脚本环境,建立了基于 DQN 的纵向加速度控制算法。最后,将 RF 汇入决策模型嵌入 DQN 纵向加速度控制算法中,实现了 ICV 汇入决策和纵向加速度控制的融合。将 SUMO 内置的 LC2013 换道模型与 DQN 模型融合为 DQN-LC2013 模型,作为基线模型与 DQN-RF 模型进行对比。研究结果表明:相较于未考虑类人化汇入决策的 DQN-LC2013 模型,考虑类人化汇入决策的 DQN-RF 模型获得了更高的奖励值;当加速度动作取值空间为[-1,2] $m \cdot s^{-2}$时,DQN-RF 和 DQN-L2013 控制下的 ICV 通过汇入控制区域的平均加速度分别为 0.55、0.09 $m \cdot s^{-2}$,通过汇入控制区域的速度分别为 21.4、19.7 $m \cdot s^{-1}$;DQN-RF 模型控制下 ICV 无停车等待现象,DQN-LC2013 控制下 ICV 在 100 次汇入过程中出现了 7 次停车等待。提出的 DQN-RF 汇入控制模型可以实现类人化的驾驶决策,提高 ICV 通过汇入控制区域的效率和汇入成功率,可用于 ICV 通过高速公路加速车道汇入区域的汇入决策和纵向加速度控制。

关键词:交通工程;汇入控制模型;DQN-RF;智能网联汇入车辆;加速车道;SUMO 仿真

中图分类号:U491.2 **文献标志码**:A

Human-like Merging Control of Intelligent Connected Vehicles on the Acceleration Lane

GU Meng-lu[1], GE Zhen-zhen[1], WANG Chang*[1,2], SU Yan-qi[1], GUO Ying-shi[1]

(1. School of Automobile, Chang'an University, Xi'an 710064, Shaanxi, China; 2. Key Laboratory of Transportation Industry of Automotive Transportation Safety Enhancement Technology, Chang'an University, Xi'an 710064, Shaanxi, China)

Abstract: To develop a merging control algorithm for intelligent connected vehicles (ICVs) on freeway acceleration lanes interacting with human-driven vehicles (HDVs) on the mainline, we propose a merging control model (DQN-RF). This model integrates the deep Q-network (DQN)

收稿日期:2023-04-19

基金项目:国家自然科学基金项目(52102451,52002035);陕西省重点研发计划项目(2023-YBGY-035);中央高校基本科研业务费专项资金项目(CHD300102223501)

作者简介:谷梦路(1995-),女,河北石家庄人,工学博士研究生,E-mail:gumenglu@chd.edu.cn。

*通讯作者:王 畅(1984-),男,湖南岳阳人,教授,博士研究生导师,工学博士,E-mail:wangchang@chd.edu.cn。

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

algorithm and the random forest (RF) algorithm. First, a roadside data acquisition platform was established to collect the naturalistic merging behavior data of HDVs at a typical merging zone with an acceleration lane on the G70 freeway in China. Second, a human-like merging decision model using RF was built using historical merging environmental contextual data and the merging urgency of the merging vehicle on the acceleration lane as input. We constructed a simulated merging scenario featuring an acceleration lane on the freeway using the simulation of urban mobility (SUMO) platform. Utilizing the Python language, we developed a testing script environment for the deep reinforcement learning algorithm. Additionally, we introduced a longitudinal acceleration control algorithm based on DQN. Finally, the DQN-RF merging control model, which embedded the RF merging decision algorithm into the DQN longitudinal acceleration control algorithm, was established to embrace merging decision control and longitudinal acceleration control in a comprehensive framework. The default lane-changing control algorithm in SUMO, known as "LC2013," was also combined with the proposed DQN algorithm to serve as a baseline model. The simulation results show that, with the same acceleration action value space $[-1, 2]$ m·s^{-2}, compared to the DQN-LC2013 model, the DQN-RF model receives a higher total reward value. The average accelerations of the ICV for the DQN-RF and DQN-LC2013 models are 0.55 and 0.09 m·s^{-2}, respectively. Furthermore, the average speeds are 21.4 and 19.7 m·s^{-1}, respectively. There are no stop-and-wait phenomena observed when the DQN-RF model is adopted, while there are seven stop-and-wait events in 100 turns of simulation when the DQN-LC2013 model is adopted. The proposed DQN-RF merging control model can realize human-like merging decisions and improve the merging efficiency and success rate of the ICV. The DQN-RF model can be used for merging decision control and longitudinal acceleration control of the ICVs on the freeway acceleration lane.

Keywords: traffic engineering; merging control model; DQN-RF; intelligent connected vehicle; acceleration lane; SUMO simulation

Received 19 Apr. 2023

Funding: National Natural Science Foundation of China (52102451, 52002035); Shaanxi Key Research and Development Program (2023-YBGY-035); Fundamental Research Funds for the Central Universities (CHD300102223501)

*Corresponding author. *E-mail address*: wangchang@chd.edu.cn.

https://doi.org/10.19721/j.cnki.1001-7372.2024.03.005

0 引　言

智能网联技术在汽车上的应用推动了汽车智能化产业的发展，在促进交通安全、提高车辆运行效率方面影响深远。然而，目前的道路基础设施和技术水平尚不能支撑实现智能网联车辆(Intelligent Connected Vehicle, ICV)的全面覆盖，ICV 和传统人工驾驶车辆(Human-driven Vehicle, HDV)的混行模式将长期存在。混行模式下 ICV 的运动决策控制研究将有助于推动 ICV 的快速应用落地。高速公路加速车道汇入区域是容易发生交通冲突的典型区域，研究加速车道 ICV 与主线 HDV 交互时 ICV 通过该汇入区的运动控制算法意义重大。

Schieben 等[1]认为混行模式下，自动驾驶车辆要能够实现安全、直接地与其他道路交通参与者进行交互。这要求自动驾驶车辆要以类人化的驾驶方式驾驶以避免其行为误导行人、乘客和其他人类驾驶人[2]。Sharath 等[3]认为智能车辆的类人化驾驶会增加其可接受度，促进交通安全。智能车辆的类人化驾驶可能会促进传统车辆驾驶人对其行为的正确感知[4]，提高交通的和谐程度[5]。因此，ICV 与 HDV 交互时运动控制算法的研究应基于真实的 HDV 运行数据，学习人类驾驶人的驾驶行为方式，以实现类人化驾驶。

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

前人的研究一般将换道行为分为强制换道和自由换道 2 种，其中强制换道是指为了达到预期地点而进行的换道，而自由换道则是为了寻求更高的驾驶速度或者寻求更优的驾驶环境等[6]。高速公路加速车道的换道行为属于一种强制换道行为。对于换道决策行为，研究人员基于真实的 HDV 自然驾驶数据已经做了大量研究。从 1986 年 Gipps 等[7]提出考虑换道可行性、必要性和换道意愿的换道决策框架伊始，基于各种规则和算法的换道决策模型层出不穷。其中包括：基于换道车辆和环境车辆最小安全距离的换道决策模型，如许伦辉等[8]提出的椭圆最小安全距离模型和 Li 等[9]提出的基于安全势场理论的最小安全距离模型；基于可接受前后车间隙的换道决策模型，如 Hou 等[10]建立的基于贝叶斯和决策树的联合分类模型，Balal 等[11]建立的模糊推理系统模型，叶颖俊等[12]通过风险空间理论和期望反应时间建立的主线后车间隙风险边界；基于效用理论的换道决策模型，如 Arbis 等[13]和 Kang 等[14]提出的基于博弈论的并线模型；基于物理过程特征的换道决策模型，如 Jian 等[15]提出的元胞自动机模型，曲大义等[16]提出的基于分子动力学的换道模型；基于深度学习的换道决策模型，如 Xie 等[17]提出的基于深度信念网络和长短时记忆网络的换道决策模型。

目前关于智能网联车辆换道行为的研究，可以分为区域换道决策和区域协同控制两方面。区域换道决策主要研究在控制区域内智能网联车辆的换道决策行为，多以提高该被控车辆或者区域整体的驾驶效率为研究目标。赵建东等[18]结合深度强化学习和分子动力学理论，提出了一种融合掩码机制和注意力机制的双深度 Q 网络（Mask-attention-DDQN，MAQ）换道决策模型，将智能网联车换道模式分为向左、向右、车道保持，该模型提高了智能网联车辆的平均速度；张鑫辰等[19]基于 Dueling DDQN 深度强化学习算法建立了高速公路场景中智能车辆的换道决策模型，将换道决策分为向左、向右、车道保持、加速和减速 5 类，该模型提高了智能车辆换道决策的成功率和驾驶效率。区域协同控制，通过对控制区域智能网联车辆进行联合协同控制，旨在提高控制区域的整体安全性和驾驶效率。Hu 等[20]研究了全网联环境下智能网联车辆的多车道协同汇入控制，分为上游主线车辆协同换道控制和并线区域协同汇入控制。Ding 等[21]研究了不同智能网联车辆渗透率下车辆通过汇入区域的并线顺序和运动控制方法，发现当智能网联车辆渗透率达到 30%时能够有效减少交通流振荡并减少交通拥堵。

总结前人研究发现以下问题：

（1）对传统车辆的换道决策行为研究已经趋于成熟。随着智能化、网联化车辆发展方向被人们所认可，关于网联环境下智能网联车辆换道决策行为、协同控制研究也逐渐增多。但是，对于传统车辆 HDV 向智能网联车辆 ICV 转换的过渡阶段，ICV 和 HDV 交互时 ICV 的换道决策、汇入行为分析研究较少。鉴于高速公路加速车道汇入路段三角区特殊道路结构以及 ICV 车载传感器的探测范围限制，ICV 可能无法识别主线 HDV 运行状态信息。如何使 ICV 实现类人化的汇入决策，与主线 HDV 和谐交互、减少冲突、安全高效地通过汇入区域是混行模式下 ICV 需要解决的问题之一。

（2）针对中国典型高速公路加速车道汇入路段的数据集较少。国内外对于换道汇入行为的研究多基于下一代交通仿真数据集（Next Generation Simulation，NGSIM）中的 US-101 和 I-80 自然驾驶数据集，其数据采集点均处于交织区，而非典型的加速车道汇入路段。此外，德国亚琛汽车工程技术有限公司布的数据集 exiD[22]包含了德国不同路段高速公路加速车道汇入口的汇入数据，但是同时也存在国内国外驾驶人驾驶行为习惯不同的问题。清华大学苏州汽车研究院和江苏省智能网联汽车创新中心联合发布的 Mirror-Traffic 数据集[23]包含了高速公路加速车道汇入路段的驾驶数据，但是该数据集中只涉及 62 辆汇入车，这对于研究不同汇入场景下的汇入决策来说数据量相对较少。

针对以上问题，本研究提出以下解决方案：

（1）通过高清摄像头和毫米波雷达组成路侧设备数据采集平台（Road-side Data Acquisition Platform，RS-DAP），采集了 G70 福银高速公路三营收费站加速车道汇入区的自然驾驶汇入交互数据，构建了典型高速公路加速车道汇入行为数据集。

（2）通过引入网联 RS-DAP 交通设施，可将主线 HDV 运行状态信息通过车路协同系统（Vehicle to Infrastructure，V2I）传递给 ICV 端，解决 ICV 感知道路环境和 HDV 信息时出现的路段盲区问题。

（3）通过分析研究典型高速公路加速车道汇入行为数据集，获取 HDV 在汇入过程中的汇入决策和汇入行为特征，使用集成学习模型和深度强化学习模型构建了 ICV 与 HDV 交互时的汇入控制方法。

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

1　汇入交通场景描述

本文针对高速公路平行式加速车道汇入路段，如图 1 所示，研究对象为加速车道上的 ICV 汇入车，主线车辆为 HDV。

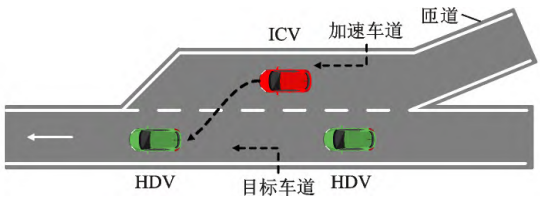

图 1　汇入交通场景

Fig. 1　Merging Scenario

在图 1 的交通场景中，主线车道 HDV 和加速车道 ICV 存在较为明显的速度差，且 ICV 受到剩余加速车道长度的影响，汇入行为需要在有限的距离内完成，因此相比于传统道路的换道行为，ICV 的汇入行为风险更大。本文通过建立 RS-DAP，采集真实车辆汇入交互行为数据，根据真实道路汇入车汇入时环境车辆运行状态信息和剩余加速车道长度的影响，建立类人化的 ICV 汇入决策模型。同时，根据真实道路汇入车汇入过程中的加速度分布、汇入位置分布等特征，完善了 ICV 纵向加速度控制算法的奖励函数，最终实现了 ICV 通过高速公路加速车道的汇入决策和纵向加速度控制，并用 SUMO 仿真平台验证了汇入控制模型的合理性。本文整体架构如图 2 所示。

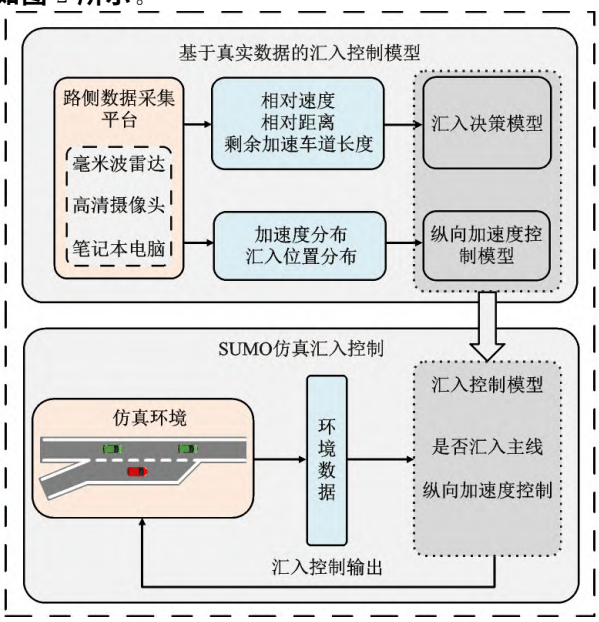

图 2　ICV 汇入控制研究框架

Fig. 2　Overall Architecture of the Proposed ICV Merging Control Scheme

2　数据准备

2.1　数据采集

将高清摄像头和毫米波雷达组成路侧设备采集平台 RS-DAP，经过时间校正后安装于汇入匝道与主线道路硬隔离区末端，如图 3 所示。RS-DAP 通过毫米波雷达获取车辆位置、速度、角度信息，通过高清摄像头记录驾驶场景信息。汇入数据采集路段的主线限速值为 120 km·h^{-1}，加速车道的长度为 156 m。

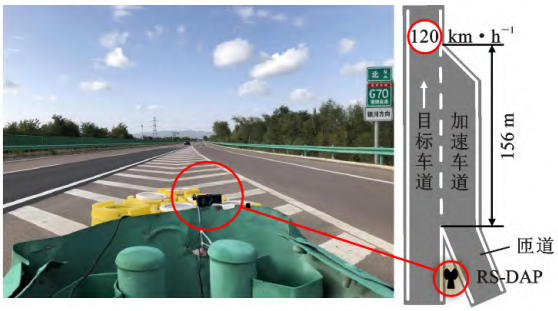

图 3　数据采集路段及 RS-DAP 安装位置

Fig. 3　Data Collection Scenario and RS-DAP Installation Position

本文所用的雷达为 Delphi 公司的 ESR 毫米波雷达，其探测范围为以雷达为中心左右 45°，监测距离为 200 m，可同时稳定追踪 64 个目标，能覆盖视频区域加速车道范围，并将监测目标数据存储于与之相连接的笔记本电脑中。摄像头的视频采集速率为 30 帧·s^{-1}，雷达采集速率为 20 Hz。

试验采用的雷达和摄像头较小，且安装位置隐秘，不易被驾驶人发现，因此，该 RS-DAP 不会对驾驶人的驾驶行为产生干扰，可获得真实可靠的驾驶行为数据。该数据采集装备可实现对驾驶行为的连续采集，数据采集累计时长约 16 h，监测到了超过 2 000辆汇入车的汇入过程，其中单车汇入过程约 1 000组。数据采集路段道路交通流量分布在 2 500～5 560 veh·h^{-1}之间(非拥堵条件，无停走现象)，主线车辆平均速度约为 22～33 m·s^{-1}，加速车道汇入车平均速度约为 19 m·s^{-1}，汇入时的平均速度约为 20 m·s^{-1}，汇入车在加速度车道上的平均加速度为 0.41 m·s^{-2}。

2.2　数据预处理

典型汇入场景包含 3 辆目标车辆，如图 4 所示，包括加速车道的汇入车 MV、目标车道前车 LV 和目标车道后车 FV。RS-DAP 的毫米雷达波束中心与 MV、LV 和 FV 之间的夹角分别为 α_M、α_L 和 α_F，

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

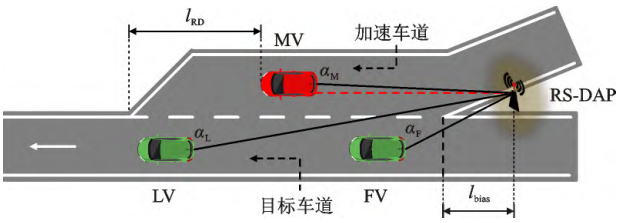

图 4 典型加速车道汇入场景

Fig. 4 Typical Merging Scenario on the Acceleration Lane

MV 距离加速车道终点的距离为 l_{RD}，RS-DAP 距离加速车道起点的距离为 l_{bias}。

假设车辆的动态信息向量 $\boldsymbol{D}=(v,x)_V$，其中 v 为车辆的纵向速度，x 为车辆距离加速车道起点的纵向位置，$V=\{MV,LV,FV\}$。RS-DAP 采集的车辆动态参数向量为 $\mathcal{D}=(\mathcal{V},\mathcal{X},\alpha)_V$，$\mathcal{V}$ 为 RS-DAP 采集的车辆速度，$\mathcal{X}$ 为 RS-DAP 测得的车辆距离，α 为 RS-DAP 测得的车辆角度。由于数据采集过程中存在噪声，本文采用 MATLAB R2021b 小波包工具箱对采集数据进行去噪，采用三层小波包分解和重构对 RS-DAP 采集的数据进行去噪处理。

由于余弦效应的存在，车辆的真实运动状态参数与 RS-DAP 采集数据之间的关系为

$$(v,x)=(\mathcal{V},\mathcal{X})\begin{bmatrix}1/\cos(\alpha) & 0\\ 0 & \cos(\alpha)\end{bmatrix}-(0,l_{bias})=(\mathcal{V}/\cos(\alpha),\ \mathcal{X}\cos(\alpha)-l_{bias}) \tag{1}$$

当车辆刚驶入 RS-DAP 监控范围时，α 的绝对值较大，余弦效应显著，随着车辆驶离 RS-DAP，α 的绝对值不断减小，余弦效应减小，当 $|\alpha|\leqslant 3°$（$\cos(\pm 3°)\approx 0.998\ 6$）时余弦效应可忽略。图 5 是 RS-DAP 采集的汇入区域某车辆的原始速度和经过余弦校正后的速度对比。

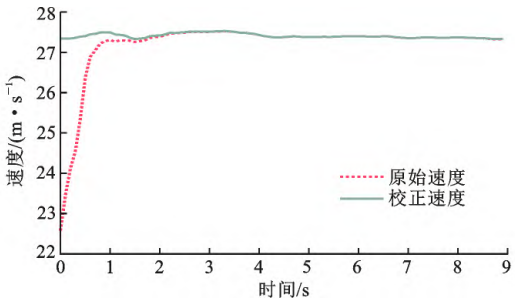

图 5 余弦校正后速度与原始速度对比

Fig. 5 Comparison of the Raw Speed Data and the Cosine Corrected Speed Data

3 ICV 汇入控制模型

3.1 ICV 类人化汇入决策模型

基于 MV 是否接受当前汇入环境中 LV 和 FV 之间的间隙，将当前的汇入场景分为“汇入”事件和“非汇入”事件。由于主线和加速车道存在明显的速度差，主线后车是影响 MV 汇入的主要因素。因此，本文主要研究 MV 汇入时主线存在后车，或者存在前后车的场景，其中包括“汇入”事件 388 组，“非汇入”事件 196 组。由于汇入决策模型的意义在于确定当前汇入场景周车位置、状态信息以判断汇入可能性，进而在 MV 发生横向运动前提供汇入决策建议，因此本文只考虑环境车辆的纵向运动状态特征，即认为车辆的纵向位置关系特征和纵向加减速状态变化是影响汇入决策的主要因素。

MV 的汇入决策行为会受到汇入紧迫度 U 的影响。在本研究中，l_{RD} 与 U 的关系为

$$U=(L-l_{RD})/L \tag{2}$$

式中：L 为加速车道总长度。

当 MV 到达加速车道起点时，$l_{RD}=L$，U 为最小值 0，此时汇入紧迫度最低，当 MV 到达加速车道终点时，$l_{RD}=0$ m，U 最为大值 1，此时汇入紧迫度最高。随着 MV 在加速车道上运行，l_{RD} 不断减小，U 不断增大，U 的取值范围为[0,1]。

由于车辆运行状态始终处于动态变化之中，考虑历史环境信息将捕获车辆运行状态改变规律，从而预测车辆运行状态的改变趋势，进而提高汇入场景的决策准确率，本研究引入当前时刻前 1 s 内的状态信息作为汇入决策模型输入。汇入场景的环境信息输入向量可表示为 $\boldsymbol{I}=(I_0,I_{0.1},I_{0.2},\cdots,I_t,\cdots,I_{0.9},I_{cur})$。$I_t$ 表示某一时刻汇入场景中的环境信息，$\boldsymbol{I}$ 包含当前时刻的环境信息 I_{cur} 以及从当前时刻起前 1 s 内的历史环境信息，环境信息更新时间间隔为 0.1 s。其中，$I_t=(v_{MV},v_{LM},v_{MF},x_{LM},x_{MF},U)_t$，$v_{MV}$ 为汇入车 MV 的纵向速度；v_{LM} 和 v_{MF} 分别为 MV 与目标车道 LV、FV 的相对速度；x_{LM} 和 x_{MF} 分别为 MV 与 LV、FV 的相对距离。由于 I_t 为 6 维向量，因此 $\boldsymbol{I}$ 的维度为 66，即样本总特征数 $N_{tot}^{pre}=66$。

模型汇入决策输出为 $O=\{O_{LC},O_{LK}\}$，其中 O_{LC} 表示当前环境状态下“可换道”，O_{LK} 表示当前环境状态下 MV 应该执行“车道保持”。以 $\Delta t=0.1$ s 为离散时间滑动步长遍历“汇入”事件和“非汇入”事件，共得到 O_{LC} 样本和 O_{LK} 样本 7 206 组。如图 6 所示，图 6(a)表示“汇入”事件，从 T_s 到 T_c 这一过程中，每一离散时刻的环境状态标签为“可换道”O_{LC}。图 6(b)表示“非汇入”事件，从 T_s 到 T_f 这一过程中，每一离散时刻的环境状态标签为“车道保持”O_{LK}，T_f 时刻后 FV 变成新的 LV，MV 将开始新一

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

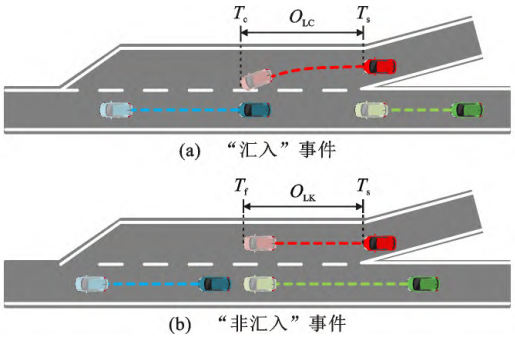

图 6　离散时刻决策标签

Fig. 6　Decision Labels at Discrete Time Instants

轮的决策。由于人类驾驶人的反应时间通常在 0.3～1.0 s，其决策频率要小于 ICV，通过以上离散时刻汇入标签确定方法，可以使得 ICV 的宏观间隙接受行为与人类驾驶车辆一致。

以 O_{LC} 样本为正样本（Positive Sample），n_{TP} 表示模型正确识别 O_{LC} 样本的个数，n_{TN} 表示正确识别 O_{LK} 样本的个数，n_{FP} 表示错误地将 O_{LK} 样本识别为 O_{LC} 样本的个数，n_{FN} 表示错误地将 O_{LC} 样本识别为 O_{LK} 样本的个数。以 $\boldsymbol{I}$ 为输入，O 为输出，训练集和测试集的比例为 3∶1（训练集 5 404 组，测试集 1 802 组），对比随机森林模型（Random Forest，RF）、取 k 为 20 的 k 最邻近模型（k-Nearest Neighbor，k-NN）、逻辑回归模型（Logistic Regression，LR）、包含 2 个隐含层的神经网络模型（Neural Network，NN）、支持向量机模型（Support Vector Machine，SVM）、朴素贝叶斯模型（Naive Bayes，NB）的分类结果，各模型的表现如表 1 所示。

表 1　各分类模型表现对比

Table 1　Comparison of Models' Performances

模型	准确率/%	精确率/%	召回率/%	F1-score/%
RF	98.5	98.3	99.3	98.8
k-NN	91.9	93.3	93.9	93.6
LR	93.1	94.1	95.0	94.5
NN	92.2	93.2	94.6	93.9
SVM	89.5	91.2	92.3	91.7
NB	87.2	93.1	86.1	89.5

各分类模型的受试者工作特性（Receiver Operating Characteristics，ROC）曲线和 ROC 曲线下方面积（Area Under the Curve，S_{AUC}）值如图 7 所示。其中假正率 $R_{FP}=n_{FP}/(n_{TN}+n_{FP})$，真正率 $R_{TP}=n_{TP}/(n_{TP}+n_{FN})$。

由表 1 和图 7 可以得出，RF 模型在 O_{LC} 和 O_{LK} 样本的分类问题上获得了最高的模型准确率、精确率、召回率以及 F1-score，同时 RF 模型 ROC 曲线的 S_{AUC} 值最大，这表明相较于本研究提到的其他模型，RF 模型在汇入决策分类问题上表现最优。

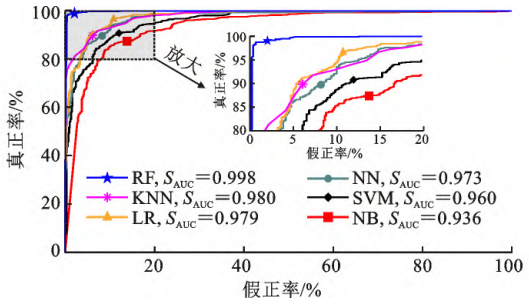

图 7　不同分类模型的 ROC 曲线对比

Fig. 7　Comparison of ROC Curves of Different Classifiers

本文中 RF 模型每个决策树选用的随机特征个数 $N_{tree}^{pre}=\sqrt{N_{tot}^{pre}}\approx 8$，叶子节点数 $N_{tree}^{leaf}=1$，特征选择方法采用 Gini 系数法，每个树以最大限度生长而不进行剪枝，决策树总数为 $N_{tree}^{num}=100$。为了进一步探究不同决策树结构下不同随机森林模型表现差异，分别以不同的 N_{tree}^{leaf} 和 N_{tree}^{split} 建立随机森林模型，以决策树桩（单一决策树，$N_{tree}^{split}=1$）为基线模型，对比模型分类误差率如图 8 所示。

由图 8 可知，决策树桩模型的误分类率最大；当 $N_{tree}^{leaf}=1,2,3$ 时，RF_5、RF_{15}、RF_{30} 和 RF（本文使用）模型的误分类率没有显著变化；当 N_{tree}^{split} 增大时，RF_5、RF_{15}、RF_{30} 和 RF 模型的误分类率依次减小；随着 N_{tree}^{num} 的增大，随机森林模型的表现趋于稳定。当不限制 N_{tree}^{split} 且 $N_{tree}^{leaf}=1$ 时，RF 模型在 $N_{tree}^{num}=100$ 的误分类率为 0.015 1，相比于其他模型表现最优，即本文提出的 RF 模型决策树结构合理，表现较好。

为了研究 U 对模型分类准确率的影响，将不考虑特征 U 时各模型的表现总结如表 2 所示，相比于考虑 U 时的模型，未考虑 U 时的 RF、k-NN、LR、NN、SVM 和 NB 模型的整体识别准确率分别降低了 0.9%、1.4%、1.0%、1.3%、1.1% 和 1.5%。这是因为，高速公路加速车道的汇入行为可能会受到加速车道剩余长度的影响，不同 U 下汇入车驾驶人的汇入决策可能不同。因此，必须要将 U 考虑在汇入模型之中。

表 2　不考虑 U 时各分类模型表现对比

Table 2　Models' Performances Removing the Impact of U

模型	准确率/%	精确率/%	召回率/%	F1-score/%	S_{AUC}
RF	97.6	97.5	98.6	98.1	0.995
k-NN	90.5	90.2	94.7	92.4	0.975
LR	92.1	92.1	95.3	93.7	0.968
NN	90.9	91.8	93.5	92.6	0.964
SVM	88.4	90.8	90.8	90.8	0.955
NB	85.7	92.5	84.2	88.2	0.932

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

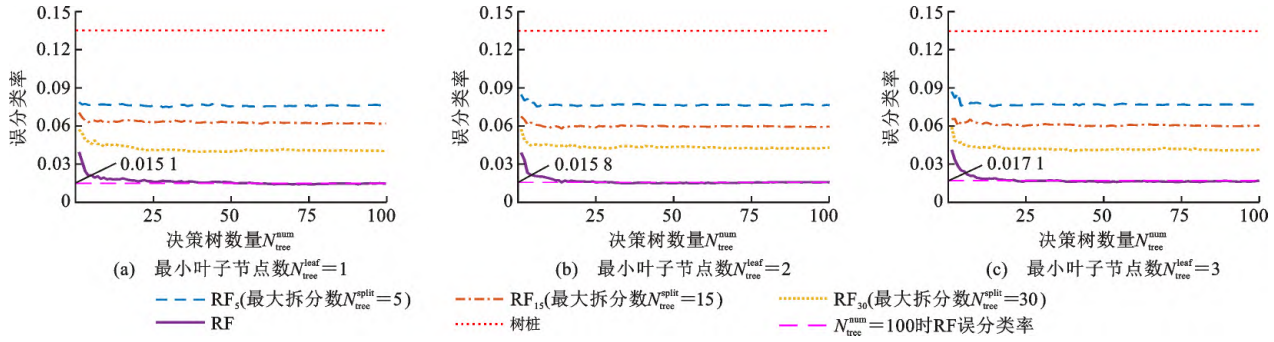

图 8 模型分类误差率

Fig. 8 Misclassification Rate of Different Models

本节基于真实的 HDV 汇入场景数据建立了 MV 的汇入决策模型 RF 模型，该模型综合了汇入场景环境信息数据和 MV 汇入紧迫度 U，实现了 O_{LC} 和 O_{LK} 样本的高准确率分类。

3.2 深度 Q 网络(Deep Q-Network，DQN)纵向加速度控制算法

RF 汇入决策模型可实现决策层面的 ICV 类人化汇入控制，然而，从操作层面来说，如何控制加速车道上 ICV 的纵向加速度以使其安全、高效、稳定地通过汇入区域，仍需进一步研究。

本研究通过深度强化学习 DQN 算法来控制 ICV 通过汇入区域的纵向加速度。DQN 以马尔科夫过程为基础，智能体(ICV)通过观察当前状态 s_t 并采取动作 a_t 来与环境进行交互，环境更新状态 s_{t+1} 并给出奖励值 r_t，即 ICV 与汇入环境交互一次，得到一组当前时刻环境状态参数 $e_t=(s_t,a_t,s_{t+1},r_t)$。本研究中，DQN 通过深度神经网络 $Q(s_t,a_t;w_t)$ 来近似最优动作价值函数 $Q^{☆}(s_t,a_t)$，w_t 是神经网络的权值。其中

$$R_t^e=R_t+\gamma R_{t+1}+\gamma^2 R_{t+2}+\gamma^3 R_{t+3}+\cdots \tag{3}$$

$$\pi(s_t,a_t)=\mathbb{P}(A=a_t\mid S=s_t) \tag{4}$$

$$Q_\pi(s_t,a_t)=\mathbb{E}[R_t^e\mid S_t=s_t,A_t=a_t] \tag{5}$$

$$Q^{☆}(s_t,a_t)=\max_\pi Q_\pi(s_t,a_t) \tag{6}$$

式中：R_t^e 为未来累积折扣奖励；γ 为折扣因子；π 为策略函数，指代状态 s_t 发生时，ICV 采取动作 a_t 的概率值；$Q_\pi(s_t,a_t)$ 为策略 π 的动作价值函数，等于未来累积折扣奖励 R_t^e 的期望值；最优动作价值函数 $Q^{☆}(s_t,a_t)$ 指无论使用哪种策略函数 π，当状态为 s_t 时，采取动作 a_t 得到的动作价值函数的最大值为 $Q^{☆}(s_t,a_t)$，DQN 通过最大化奖励值 $Q^{☆}(s_t,a_t)$ 得到最优动作 a_t。

网联 RS-DAP 设施可以弥补 ICV 自身传感器探测距离限制，实现混行模式下 HDV 运动状态信息采集。将汇入行为控制模型集成在路侧网联 RS-DAP 设施端，可以降低 ICV 本身的算力负荷。另外，根据不同加速车道汇入路段的路段线形特征，可以动态调整网联 RS-DAP 前端数据预处理参数，方便模型的调试和改进。在智能网联系统中，通过网联 RS-DAP 设施采集当前汇入场景状态 $\varphi_t=(\mathcal{D}_{MV},\mathcal{D}_{LV},\mathcal{D}_{FV})_t$，状态值 s_t 为 φ_t 经过数据预处理后的值，ϕ 为数据预处理函数，即

$$s_t=\phi(\varphi_t)=(v_{MV},v_{LV},v_{FV},x_{MV},x_{LV},x_{FV},U)_t \tag{7}$$

设动作空间 A 为 ICV 的纵向加速度取值范围，通过真实汇入场景数据得到。MV 在加速车道运行的平均加速度统计值如表 3 和图 9 所示，由车辆纵向速度进行微分得到。

表 3 MV 在加速车道的平均加速度

Table 3 Average Acceleration of the MV on the Acceleration Lane

m·s^{-2}

参数	最小值	下四分位	中位数	平均值	上四分位数	最大值
平均加速度	−0.82	0.28	0.41	0.41	0.55	1.52

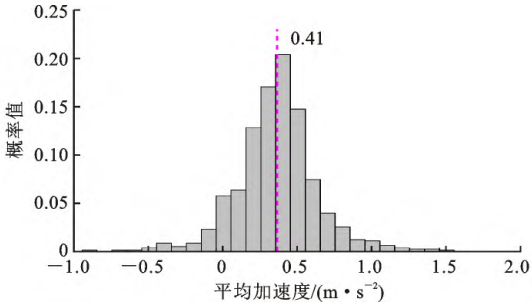

图 9 平均加速度分布

Fig. 9 Distribution of the Average Acceleration

由表 3 和图 9 知，人类驾驶车辆 MV 在汇入过程中的加速度分布区间为[−1，2] m·s^{-2}。因此本文设置 DQN 算法纵向加速度动作空间 $A=[-1,2]$，控制精度为 0.1 m·s^{-2}。

DQN 纵向加速度控制算法的奖励包括舒适度奖励 r_{comf}、位置奖励 r_{loc}、速度奖励 r_{speed}、安全奖励

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

r_{safe}、汇入成功奖励 r_{succ}，即 ICV 在一个仿真步长中得到的总奖励值为

$$r_{tot}=r_{comf}+r_{loc}+r_{speed}+r_{safe}+r_{succ} \tag{8}$$

r_{comf} 为表征加速度变化快慢的函数，如式(9)所示，l_{step} 为仿真步长，$l_{step}=\Delta t=0.1$ s，β_{comf} 取 -5.0×10^{-5}

$$r_{comf}=\beta_{comf}[(a_t-a_{t-1})/l_{step}]^2 \tag{9}$$

如式(10)所示，r_{loc} 由 2 部分构成，分别为表征 ICV 与 LV、FV 空间位置分布关系的车辆位置分布奖励 r_{loc_1}[24] 和表征 ICV 汇入位置是否符合 HDV 汇入位置规律的汇入位置分布奖励 r_{loc_2}

$$r_{loc}=r_{loc_1}+r_{loc_2} \tag{10}$$

$$r_{loc_1}=\beta_{loc_1}\left|\beta_{x_{LM}}e^{-\left(\frac{x_{LM}}{120}\right)^{0.5}}-\beta_{x_{MF}}e^{-\left(\frac{x_{MF}}{120}\right)^{0.5}}\right| \tag{11}$$

$$r_{loc_2}=\beta_{loc_2}\frac{1}{g_b^{g_a}\Gamma(g_a)}x_{MV}^{g_a-1}e^{-\frac{x_{MV}}{g_b}} \tag{12}$$

式(11)中，β_{loc_1} 取 -0.2。当 ICV 处在加速车道上时，由于高速公路主线车辆速度要显著大于汇入车的速度，逐渐减小的后车间距将增大碰撞风险，因此期望 ICV 尽可能处在 LV 和 FV 中间稍靠近 LV 的位置，本文 $\beta_{x_{LM}}$ 取 0.45，$\beta_{x_{MF}}$ 取 0.55。以前车间距 x_{LM} 和后车间距 x_{MF} 为变量对式(11)中的车辆位置分布奖励 r_{loc_1} 作图，如图 10 所示。

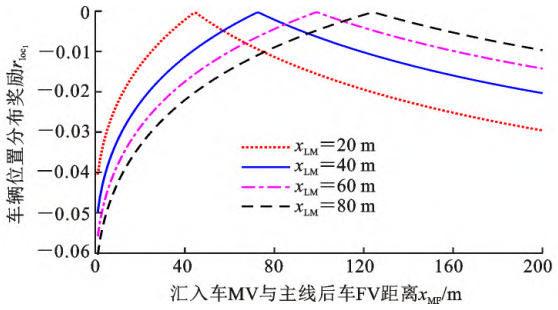

图 10　车辆位置分布奖励 r_{loc_1}

Fig. 10　Vehicle Position Distribution Reward r_{loc_1}

经过对 MV 的汇入位置进行 Gamma 函数、Lognormal 函数和 Weibull 函数分布拟合发现，汇入位置符合形状参数为 2.608，尺度参数为 16.804 的 Gamma 分布。式(12)中，ICV 的汇入位置分布奖励 r_{loc_2} 与 MV 的汇入位置分布规律趋势相同，β_{loc_2} 取 30，g_a、g_b 为 Gamma 分布的形状参数和尺度参数，$g_a=2.608$，$g_b=16.804$，Γ 表示 Gamma 函数。

r_{speed} 表示 ICV 通过汇入区域的速度奖励，式(13)中 β_{speed} 取 0.02

$$r_{speed}=\beta_{speed}\frac{v_{MV}-16}{34-16} \tag{13}$$

r_{safe} 为表征 ICV 运行安全的函数，当 ICV 发生碰撞时给予惩罚值 -1。当一个仿真步长内 ICV 未发生碰撞，给予单步奖励 $\beta_{safe}\cdot1$，如式(14)所示，其中 $\beta_{safe}=0.02$

$$r_{safe}=\begin{cases}-1 & \text{碰撞}\\ \beta_{safe}\cdot1 & \text{无碰撞}\end{cases} \tag{14}$$

r_{succ} 为表征 ICV 是否成功汇入主线的奖励函数。r_{succ_1} 表征 ICV 在当前时刻是否完成了本次汇入，当 ICV 在主线车道上时，$r_{succ_1}=1$，当 ICV 仍处于加速车道时，$r_{succ_1}=0$；r_{succ_2} 表征 ICV 本次汇入是否失败，当 ICV 发生碰撞或者停车等待时，$r_{succ_2}=-1$，否则 $r_{succ_2}=0$

$$r_{succ}=r_{succ_1}+r_{succ_2} \tag{15}$$

4　仿真验证

4.1　算法框架

ICV 汇入行为控制模型框架如下图 11 所示，首先通过 SUMO 中的 Netedit 软件编辑路网，得到与本文数据采集场景相同的汇入场景，通过 Sumo-gui 得到可视化的道路场景。汇入场景控制区域为从加速车道起点到加速车道末端前方 20 m 处。通过 Gym 工具包建立深度强化学习的测试环境，以实现对汇入控制模型的训练和测试。SUMO 仿真汇入环境通过 TraCI 接口与 Python 中的汇入控制模型 DQN-RF 进行交互。通过 Tensorflow 工具包建立 DQN 算法的 $Q(s_t,a_t;w_t)$ 神经网络，根据当前 SUMO 仿真环境中的状态向量 s_t，给出 ICV 的加速度动作 a_t，其中 $a_t\in A$。根据 SUMO 仿真环境中 ICV 当前状态和历史状态可以得到 RF 汇入决策模型的输入向量 $\boldsymbol{I}$，并得到当前汇入决策结果 O。当模型做出可换道决策时，控制仿真场景中 ICV 进行横向运动，使其完成换道操作。SUMO 仿真环境通过 a_t 和 O 控制 ICV 的动作并更新仿真环境。当 ICV 到达加速车道起点时，DQN-RF 汇入控制模型被激活，在每一个仿真步长中，DQN-RF 通过 RF 模块判断汇入可能性并给出汇入决策，DQN 模块给出该仿真步长的纵向加速度动作。当 RF 判断当前场景应执行“车道保持”时，ICV 以 DQN 给出的 a_t 在原车道运行一个仿真步长，重复进行以上过程直到 ICV 汇入并驶出控制区域。当 ICV 汇入完成后换道控制终止，此时只有 DQN 模型控制 ICV 的运动进程(ICV 发生碰撞或停车时过程终止)。

当 ICV 无法在加速车道末端之前汇入主线时，需要控制 ICV 减速停车。ICV 的安全停车控制过程如图12所示。$a_{max}^{dece}=4.5$ m·s^{-2} 为安全停车控

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

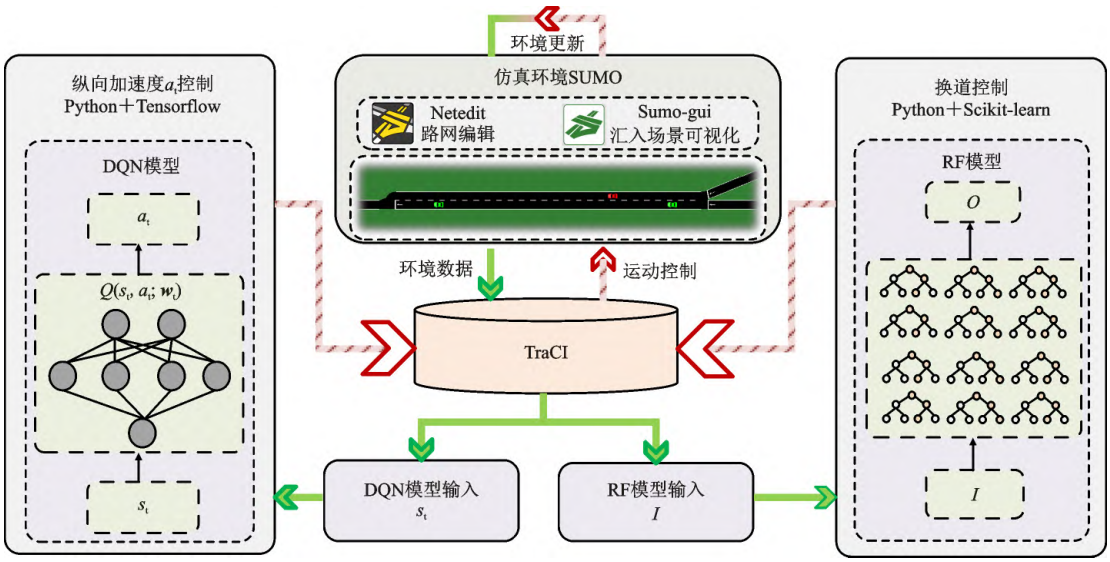

图 11 算法框架

Fig. 11 Algorithm Framework

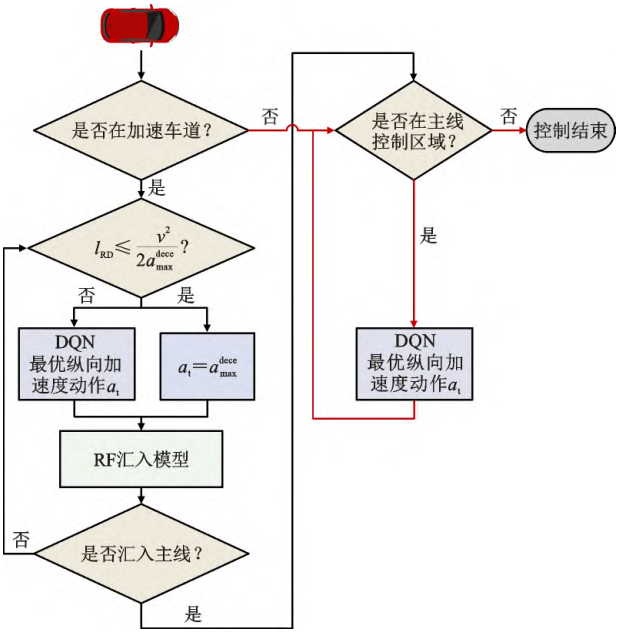

图 12 纵向安全停车控制

Fig. 12 Longitudinal Safe Stop Control

制条件满足时采用的减速度，v 为当前 ICV 的速度。当 $l_{RD} > v^2/(2a_{max}^{dece})$ 时，DQN 纵向加速度控制模型从动作空间 A 中选择最优纵向加速度动作 a_t；当 $l_{RD} \leqslant v^2/(2a_{max}^{dece})$ 时，ICV 以减速度 a_{max}^{dece} 减速，此时 RF 汇入决策判断仍然执行。当安全停车控制条件 $l_{RD} \leqslant v^2/(2a_{max}^{dece})$ 满足时，ICV 的未来运动有 2 种情况：①以减速度 a_{max}^{dece} 减速过程中汇入决策条件满足，ICV 汇入主线，之后 DQN 控制纵向加速度输出 a_t，直至 ICV 驶出控制区域；②以 a_{max}^{dece} 减速至速度 $v=0$，此时本次汇入控制场景终止，下一轮汇入场景控制开始。

SUMO 仿真环境中的参数设置和 DQN 模型的参数设置分别如表 4、5 所示。

表 4 SUMO 仿真环境参数设置

Table 4 Simulation Parameter Values in SUMO

参数	值
主线 HDV 速度	$N(\mu,\sigma)$，$\mu=27$，$\sigma=2$，范围(21，33) m·s^{-1}
主线 HDV 加速度范围	[−4.5，2.6] m·s^{-2}
主线车流量	每 θ s1辆车，$\theta \sim N(3,0.1)$
主线车辆模型	Krauss 模型[25]
ICV 速度	$N(\mu,\sigma)$，$\mu=19$，$\sigma=1.5$，范围(13.5，23.5) m·s^{-1}
车辆紧急减速度	−9 m·s^{-2}
仿真步长(Step-length)	0.1 s
车辆间最小间隙(minGap)	2 m
主线驾驶人驾驶不完美程度(Sigma)	0.5

表 5 DQN 模型参数设置

Table 5 Parameter Values of DQN Algorithm

模型	参数	值
DQN	目标网络隐含层层数和神经元个数	3，(128，256，128)
	激活函数	Relu
	学习率	0.001
	折扣因子 γ	0.99
	权重靠拢速度参数 τ	0.08
	批大小 min-batch size	32
	探索率起终止值 ε_{start}，ε_{end}	0.9，0.1

4.2 仿真结果

由于仿真场景和真实场景之间的差异无法避免，为验证模型算法的相对有效性，本文采用模型对

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

比的方式。以 SUMO 中内置的 LC2013 换道模型作为参照，建立了 DQN-LC2013 汇入行为控制参照模型。同时，设置 $A'=[-1,3]$，以对比研究加速度动作空间 A 的取值对 ICV 汇入行为的影响。主要模型和相关输入输出参数如表 6 所示。

表 6　汇入控制模型及输入输出参数

Table 6　Merging Control Models and Their Inputs and Outputs

模型	输入	输出	DQN 状态空间取值
DQN-RF	s_t，$\boldsymbol{I}$	a_t，O	$A=[-1,2]$
DQN-LC2013	s_t	a_t	$A=[-1,2]$
DQN-RF′	s_t，$\boldsymbol{I}$	a_t，O	$A'=[-1,3]$
DQN-LC2013′	s_t	a_t	$A'=[-1,3]$

使用 Tensorboard 工具包可视化模型训练过程中的奖励值如图 13 所示。当模型训练次数较少时，模型奖励值变化较大，当模型训练次数增加时，模型奖励值趋于稳定。

由图 13(a)可知，融合了 RF 汇入决策算法的 DQN-RF 模型在模型训练过程中得到了最大的总奖励值 r_{tot}；由图 13(b)知，动作空间为 $A=[-1,2]$ 的 DQN-RF 和 DQN-LC2013 模型的舒适度奖励 r_{comf} 要大于动作空间为 $A'=[-1,3]$ 的 DQN-RF′ 和 DQN-LC2013′ 模型，这可能是因为当 ICV 的纵向加速度取值范围变大时，ICV 的实际加速度在相邻仿真步长内可取值的范围更大，从而导致舒适度降低；由图 13(c)知，DQN-RF 和 DQN-RF′ 模型的位置奖励 r_{loc} 要大于 DQN-LC2013 和 DQN-LC2013′ 模型，这说明在 RF 汇入决策模型控制下，ICV 的汇入行为更加符合 HDV 的汇入决策规律，在汇入位置、距离前后车间距的表现上更加符合人类驾驶人的驾驶特征；由图 13(d)知，DQN-RF′ 模型得到了最高的速度奖励 r_{speed}，这是由于其动作空间的加速度可以取到更高的值。同时，当动作空间同为 $A=[-1,2]$ 时，DQN-RF 模型的 r_{speed} 要大于 DQN-LC2013 模型，这表明考虑类人化汇入决策的 DQN-RF 模型在 ICV 汇入行为控制上得到了更优的速度优势。

统计 100 次汇入过程中，不同模型控制下 ICV 的停车和碰撞次数，计算 ICV 在加速车道上运行的平均加速度、通过控制区域的平均速度、主线车辆通过控制区域的平均速度等参数，统计结果如表 7 所示。

由表 7 可知，在 4 种模型控制下，ICV 通过汇入区域时均未发生碰撞。考虑类人化汇入决策的模型控制下未发现 ICV 停车等待现象，这表明 RF 汇入决策模型能够更加智能地分析当前汇入环境进行汇入决策。

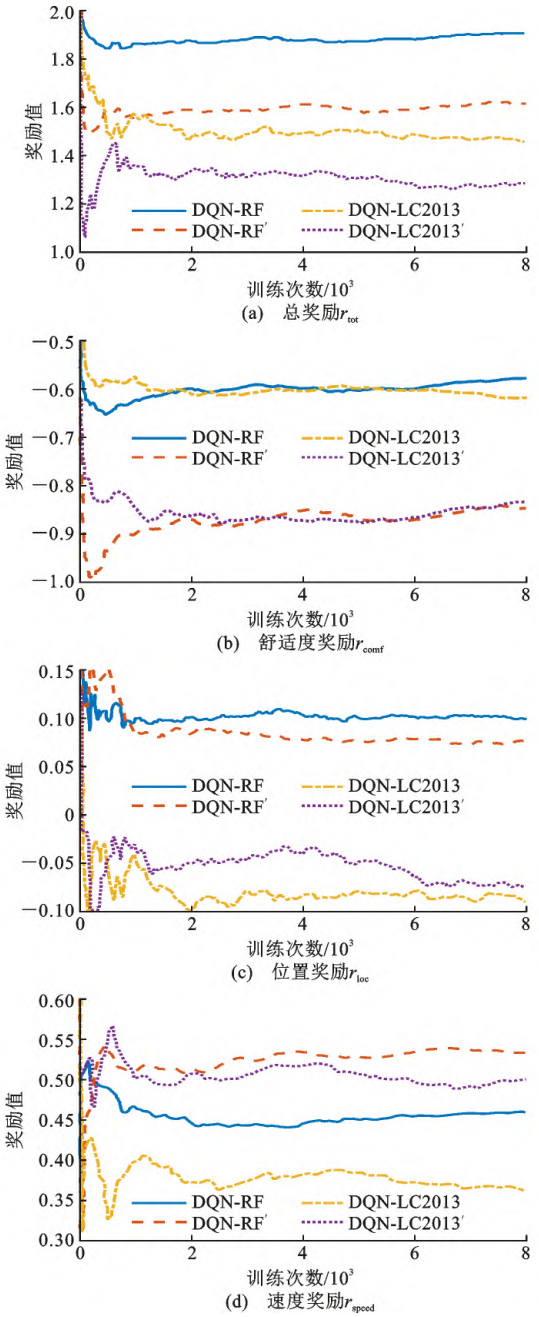

图 13　不同模型奖励值随训练次数的变化

Fig. 13　Rewards of the Different Models During Training

表 7　模型测试表现

Table 7　Models Testing Results

模型表现	DQN-RF	DQN-RF′	DQN-LC2013	DQN-LC2013′
ICV 碰撞次数	0	0	0	0
ICV 停车次数	0	0	7	8
ICV 平均加速度/(m·s^{-2})	0.55	0.69	0.09	0.40
ICV 平均速度/(m·s^{-1})	21.4	21.9	19.7	21.6
主线车辆平均速度/(m·s^{-1})	28.3	28.5	27.2	26.6

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

DQN-RF′模型控制下 ICV 在加速车道的平均加速度和通过控制区域的平均速度最大，但是相比较于 DQN-RF 模型，DQN-RF′模型的平均加速度和平均速度提升均不大。这可能是由于汇入场景的限制，在准备换道和换道过程中车辆往往不会采取较大的加速度。DQN-RF 模型中 ICV 在加速车道的平均加速度为 0.55 m·s^{-2}，Ahammed 等[26]研究得到加速车道并线过程中平均加速度的 85%分位数为 0.352 m·s^{-2}。Alyamani 等[27]研究得到非高峰交通流和高峰交通流下，并线过程中并线车辆的平均加速度均值分别为 0.532、0.398 m·s^{-2}。Hassan 等[28]研究得到加速车道加速度平均值为 0.33 m·s^{-2}。这表明 DQN-RF 模型控制下 ICV 的加速度与真实 HDV 驾驶情况较为相符。

从模型设计来看，DQN-RF 模型基于人类驾驶汇入车汇入过程数据，根据人类驾驶汇入车的间隙接受行为确定 ICV 在当前环境前后车间隙下是否进行汇入，汇入模型符合人类驾驶人的风险接受行为和驾驶习惯。从模型结果来看，DQN-RF 控制下 ICV 通过汇入路段的平均速度为 21.4 m·s^{-1}，主线车辆的平均速度为 28.3 m·s^{-1}；采用 DQN-LC2013 模型时，ICV 通过汇入路段的平均速度为 19.7 m·s^{-1}，主线车辆的平均速度为 27.2 m·s^{-1}。在 100 次汇入过程中，DQN-RF 控制下 ICV 全部完成汇入，无停车等待现象，DQN-LC2013 模型控制下的 ICV 出现了 7 次停车等待，出现了汇入失败的情况。DQN-RF′模型控制下主线车辆的平均速度最大，为 28.5 m·s^{-1}，DQN-RF 模型比 DQN-RF′模型的主线平均速度略低但相差不大，为 28.3 m·s^{-1}。DQN-LC2013 和 DQN-LC2013′模型下主线车辆平均速度相较 DQN-RF 和 DQN-RF′模型要小，DQN-LC2013′模型比 DQN-RF′模型小 1.9 m·s^{-1}。这说明 ICV 的不同汇入控制模型会对主线和 ICV 的通过效率产生影响，可以合理地认为，DQN-RF 模型相对于 DQN-LC2013 模型提升了汇入场景车辆的速度，DQN-RF 模型控制下的 ICV 与主线车辆的交互行为更加和谐。相似地，蔺庆海等[29]、陆丽萍等[30]也证实了深度强化学习算法在提升道路通行效率方面的有效性。

总结 DQN-RF 模型的类人化体现在以下方面：①汇入决策模型的类人化。由于模型以真实人类驾驶人在不同汇入场景下的行为作为真实标签，因此该汇入决策体现了类人化特征。②汇入车纵向加速度和汇入位置的类人化。汇入车的纵向加速度取值区间根据真实人类汇入车的加速度分布得到。同时，根据人类驾驶车辆的汇入位置分布为 DQN 模型设置奖励值，使得 ICV 的汇入位置分布与人类驾驶车辆相似。③DQN-RF 模型将 RF 模型和 DQN 模型进行了融合，DQN 通过奖励函数使得 ICV 通过汇入区域的奖励值最高。当由 RF 模型控制 ICV 汇入与否时，DQN 将使得 ICV 的运动向着 RF 可汇入决策发生的方向进行。这就使得 ICV 可以主动向着实现汇入的方向调整其加速度，化被动为主动，并且汇入决策符合人类驾驶人的汇入规律。

综上，考虑类人化汇入决策的深度强化学习模型要优于未考虑类人化汇入决策的深度强化学习模型，其中 DQN-RF 模型得到了最高的奖励值，使得 ICV 在汇入位置、平均加速度和平均通过速度方面更像 HDV。

5 结 语

(1)通过建立 RS-DAP，采集了真实高速公路加速度车道 HDV 汇入场景数据，建立了考虑历史数据和汇入紧迫度的 RF 汇入决策模型，模型决策准确率为 98.5%。

(2)基于 Python 语言，通过 SUMO 平台建立了深度强化学习汇入场景测试环境，通过融合 RF 汇入决策模型和 DQN 纵向加速度控制模型建立了 ICV 通过汇入区域的汇入控制模型 DQN-RF。相比较于未考虑类人化汇入决策的 DQN-LC2013 模型，DQN-RF 算法使得 ICV 通过汇入区域的平均加速度和平均速度更大、主线车辆的平均速度更大，并获得了更高的舒适度奖励、位置奖励和总奖励。当提高动作空间纵向加速度最大阈值时，ICV 的平均加速度和平均速度、主线车辆平均速度提升不大。

(3)通过设置网联 RS-DAP 可以采集主线 HDV 车辆的运行状态信息，解决汇入区域 ICV 自身传感器存在盲区的问题。可将 DQN-RF 汇入行为控制模型算法嵌入网联 RS-DAP 端，再通过 V2I 将汇入决策传递给 ICV 端，以降低 ICV 本身的算力负荷。

(4)同时，不同 RS-DAP 端可根据道路线形对 RF 汇入模型作对应调整，未来研究中应同时考虑汇入决策模型的接口，以便于后续决策模型调试优化。特别地，当出现暴雨、浓雾等极端恶劣天气时，RS-DAP 端的毫米波雷达可能由于穿透力不够而造成车辆信息检测失败，这就需要人类驾驶人在恶劣天气条件和其他复杂场景下进行接管。开发更高分

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

辨率和灵敏度、更强抗干扰能力的毫米波雷达可能是解决此问题的关键。

参考文献：

References：

[1] SCHIEBEN A, WILBRINK M, KETTWICH C, et al. Designing the interaction of automated vehicles with other traffic participants: Design considerations based on human needs and expectations [J]. Cognition, Technology & Work, 2019, 21 (1): 69-85.

[2] KADAR E E, KÖSZEGHY A, VIRK G S. Safety and ethical concerns in mixed human-robot control of vehicles [M] // ALDINHAS F M, SILVA S J, TOKHI M, et al. A World with Robots. Cham: Springer, 2017: 135-144.

[3] SHARATH M N, VELAGA N R, QUDDUS M A. 2-dimensional human-like driver model for autonomous vehicles in mixed traffic [J]. IET Intelligent Transport Systems, 2020, 14 (13): 1913-1922.

[4] VAN LOON R J, MARTENS M H. Automated driving and its effect on the safety ecosystem: How do compatibility issues affect the transition period?[J]. Procedia Manufacturing, 2015, 3: 3280-3285.

[5] GUO C Z, KIDONO K, TERASHIMA R, et al. Humanlike behavior generation in urban environment based on learning-based potentials with a low-cost lane graph [J]. IEEE Transactions on Intelligent Vehicles, 2018, 3 (1): 46-60.

[6] ZHENG Z D. Recent developments and research needs in modeling lane changing [J]. Transportation Research Part B: Methodological, 2014, 60: 16-32.

[7] GIPPS P G. A model for the structure of lane-changing decisions [J]. Transportation Research Part B: Methodological, 1986, 20 (5): 403-414.

[8] 许伦辉，胡三根，罗　强，等. 基于驾驶员类型的车辆换道模型[J]. 华南理工大学学报(自然科学版)，2014，42(8)：104-111.
XU Lun-hui, HU San-gen, LUO Qiang, et al. Lane-changing model based on different types of drivers [J]. Journal of South China University of Technology (Natural Science Edition), 2014, 42 (8): 104-111.

[9] LI L H, GAN J, ZHOU K, et al. A novel lane-changing model of connected and automated vehicles: Using the safety potential field theory [J]. Physica A: Statistical Mechanics and Its Applications, 2020, 559: 125039.

[10] HOU Y, EDARA P, SUN C. Modeling mandatory lane changing using Bayes classifier and decision trees [J]. IEEE Transactions on Intelligent Transportation Systems, 2014, 15 (2): 647-655.

[11] BALAL E, CHEU R L. Comparative evaluation of fuzzy inference system, support vector machine and multilayer feed-forward neural network in making discretionary lane changing decisions [J]. Neural Network World, 2018, 28 (4): 361-378.

[12] 叶颖俊，倪　颖，孙　剑. 高密度瓶颈交通流主动-回应汇入行为定义与建模[J]. 中国公路学报，2022，35(8)：278-290.
YE Ying-jun, NI Ying, SUN Jian. Defining and modeling active-responsive merging behavior at high-density expressway on-ramp bottlenecks [J]. China Journal of Highway and Transport, 2022, 35 (8): 278-290.

[13] ARBIS D, DIXIT V V. Game theoretic model for lane changing: Incorporating conflict risks [J]. Accident Analysis & Prevention, 2019, 125: 158-164.

[14] KANG K, RAKHA H A. A repeated game freeway lane changing model [J]. Sensors, 2020, 20 (6): 1554.

[15] JIAN M Y, LI X J, CAO J X. Investigating model and impacts of lane-changing execution process based on CA model [J]. International Journal of Modern Physics C, 2020, 31 (12): 2050171.

[16] 曲大义，张可琨，王　韬，等. 自动驾驶车辆换道决策行为分析及分子动力学建模[J/OL]. 吉林大学学报(工学版)，(2022-10-20)[2023-06-02]. https://doi.org/10.13229/j.cnki.jdxbgxb20220465.
QU Da-yi, ZHANG Ke-kun, WANG Tao, et al. Analysis of lane-changing decision-making behavior and molecular dynamics modeling for autonomous vehicles [J/OL]. Journal of Jilin University (Engineering and Technology Edition). (2022-10-20) [2023-06-02]. https://doi.org/10.13229/j.cnki.jdxbgxb20220465.

[17] XIE D F, FANG Z Z, JIA B, et al. A data-driven lane-changing model based on deep learning [J]. Transportation Research Part C: Emerging Technologies, 2019, 106: 41-60.

[18] 赵建东，贺晓宇，余智鑫，等. 多网联范围下的智能网联车换道决策组合模型研究[J]. 交通运输系统工程与信息，2023，23(1)：77-85.
ZHAO Jian-dong, HE Xiao-yu, YU Zhi-xin, et al. A combination model for connected and autonomous vehicles lane-changing decision-making under multi connectivity range [J]. Journal of Transportation Systems Engineering and Information Technology, 2023, 23 (1): 77-85.

[19] 张鑫辰，张　军，刘元盛，等. 基于 Dueling DDQN 的无人车换道决策模型[J]. 东北师大学报(自然科学版)，2022，54(1)：63-71.
ZHANG Xin-chen, ZHANG Jun, LIU Yuan-sheng, et al. Autonomous vehicle lane change strategy model based on dueling double deep Q network [J]. Journal of Northeast Normal University (Natural Science Edition), 2022, 54 (1): 63-71.

[20] HU X W, SUN J A. Trajectory optimization of connected and autonomous vehicles at a multilane freeway merging area [J]. Transportation Research Part C: Emerging Technologies, 2019, 101: 111-125.

[21] DING J, PENG H, ZHANG Y, et al. Penetration effect of connected and automated vehicles on cooperative on-ramp merging [J]. IET Intelligent Transport Systems, 2020, 14 (1): 56-64.

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

[22] MOERS T, VATER L, KRAJEWSKI R, et al. The exiD dataset: A real-world trajectory dataset of highly interactive highway scenarios in Germany [C] // IEEE. 2022 IEEE Intelligent Vehicles Symposium (IV). New York: IEEE, 2022: 958-964.

[23] **江苏省智能网联汽车创新中心. 数据集**[EB/OL]. [2023-06-02]. http://www.scenarios.cn//html/dataset.html#detail.
Jiangsu Intelligent Connected Automotive Innovation Center. About the Dataset [EB/OL]. [2023-06-02]. http://www.scenarios.cn//html/dataset.html#detail.

[24] EL ABIDINE KHERROUBI Z, AKNINE S, BACHA R. Novel decision-making strategy for connected and autonomous vehicles in highway on-ramp merging [J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23 (8): 12490-12502.

[25] KRAUSS S, WAGNER P, GAWRON C. Metastable states in a microscopic model of traffic flow [J]. Physical Review E, 1997, 55 (5): 5597-5602.

[26] AHAMMED M A, HASSAN Y, SAYED T A. Modeling driver behavior and safety on freeway merging areas [J]. Journal of Transportation Engineering, 2008, 134 (9): 370-377.

[27] ALYAMANI M, HASSAN Y. Driver behavior on freeway entrance ramp terminals [J]. Journal of Transportation Engineering, Part A: Systems, 2021, 147 (12): 04021090.

[28] HASSAN Y, SARHAN M, SALEHI M. Probabilistic model for design of freeway acceleration speed-change lanes [J]. Transportation Research Record: Journal of the Transportation Research Board, 2012 (2309): 3-11.

[29] **蔺庆海,何兆成,谢 俊,等. 基于 AVI 数据与深度强化学习的城市快速路匝道协调控制方法**[J]. **中国公路学报**, 2023, 36 (10): 224-237.
LIN Qing-hai, HE Zhao-cheng, XIE Jun, et al. Urban expressway coordinated ramp metering approach using automatic vehicle identification data and deep reinforcement learning [J]. China Journal of Highway and Transport, 2023, 36 (10): 224-237.

[30] **陆丽萍,程 垦,褚端峰,等. 基于竞争循环双 Q 网络的自适应交通信号控制**[J]. **中国公路学报**, 2022, 35(8): 267-277.
LU Li-ping, CHENG Ken, CHU Duan-feng, et al. Adaptive traffic signal control based on dueling recurrent double Q network [J]. China Journal of Highway and Transport, 2022, 35 (8): 267-277.

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net