第 38 卷 第 1 期
2025 年 1 月

中 国 公 路 学 报
China J. Highw. Transp.

Vol. 38 No. 1
Jan. 2025

文章编号:1001-7372(2025)01-0268-13

考虑换道风险动态评估的快速路合流区 CAV 换道决策模型

程国柱*,孟凤威,陈永胜,吕家乐,王文志
(东北林业大学 土木与交通学院,黑龙江 哈尔滨 150040)

摘要:城市快速路作为重要交通走廊,其合流区交通调度更为复杂。为保障智能网联车辆(Connected and Automated Vehicle, CAV)在城市快速路合流区高效、安全、舒适行驶,基于城市快速路合流区的换道特征,开展了考虑换道风险动态评估结果的 CAV 换道决策模型的相关研究。首先,对换道车辆与邻车进行时空重叠分析,将分析结果作为潜在风险判别依据,对存在时空重叠的 CAV 及其邻车计算换道碰撞时间(Lane Change Time to Collision, LCTTC),实现换道风险动态评估;然后,将换道风险动态评估结果融入多目标奖励函数优化的 DQN(Deep Q-Network)网络结构,并综合考虑车辆行驶高效性、安全性与舒适性等因素,提出具有风险感知的 SIDQN(Security Improvement Deep Q-Network)换道决策;最后,通过仿真试验进行验证。研究结果表明:相较于对比策略,提出的 SIDQN 策略换道成功率保持在 95% 以上,且运行平均速度不低于 21.008 $m \cdot s^{-1}$;此外,在复杂的交通合流场景中,融入安全性奖励的 SIDQN 策略表现出最佳安全性,其 LCTTC 平均占比仅为 9.56%,远低于其他对比策略,同时事故率统计结果持续保持较低水平;在舒适性方面,SIDQN 策略下换道次数仅为 4 次,连续换道和无效换道次数均为 1 次,并显著降低了频繁换道和极端加速减速操作次数,提升了乘客的舒适体验。提出的换道决策模型综合性能优势明显,可为智能网联环境下城市快速路合流区 CAV 安全换道决策研究提供参考。

关键词:交通工程;换道决策;深度强化学习;智能网联车辆;换道风险评估;快速路合流区
中图分类号:U491 **文献标志码:**A

CAV Lane Change Decision-making Model in Urban Expressway Merging Areas Considering Dynamic Lane Change Risk Assessment

CHENG Guo-zhu*, MENG Feng-wei, CHEN Yong-sheng, LYU Jia-le, WANG Wen-zhi
(School of Civil Engineering and Transportation, Northeast Forestry University, Harbin 150040, Heilongjiang, China)

Abstract: Urban expressways, as essential transportation corridors, present unique challenges for traffic management, especially in merging zones. This study proposes a lane change decision-making model for connected and automated vehicles (CAVs) designed to optimize their operation in these complex environments. Specifically, the model addresses the unique lane change dynamics in urban expressway merging zones, focusing on safety, efficiency, and comfort. The analysis begins with a spatiotemporal overlap evaluation between lane-changing vehicles and

收稿日期:2024-05-31
基金项目:中央高校基本科研业务费专项资金项目(2572023CT21);国家自然科学基金项目(52378433);黑龙江省重点研发计划项目(JD22A014)
* **作者简介:**程国柱(1977-),男,吉林长春人,教授,博士研究生导师,工学博士,E-mail:guozhucheng@126.com。

中国知网 https://www.cnki.net

adjacent traffic, providing the basis for identifying potential collision risks. For CAVs and neighboring vehicles exhibiting spatiotemporal overlap, the lane change time to collision (LCTTC) is computed, enabling dynamic risk assessment. The resulting risk metrics are integrated into a multi-objective reward function to optimize the deep q-network (DQN) architecture, which balances vehicle safety, operational efficiency, and passenger comfort. A novel, risk-aware lane change strategy, termed the security improvement deep q-network (SIDQN), is then proposed. Simulation experiments validate the effectiveness of this strategy, with results demonstrating a lane change success rate exceeding 95% and an average speed of no less than 21.008 $m \cdot s^{-1}$. Moreover, the SIDQN strategy improves safety performance in complex merging scenarios, reducing the LCTTC ratio to just 9.56%, a substantial decrease compared to baseline strategies. The accident rate remains minimal. Additionally, the SIDQN strategy limits the number of lane changes to four and minimizes ineffective consecutive lane changes, reducing extreme acceleration and deceleration events and thereby enhancing passenger comfort. In conclusion, the proposed lane change decision-making model significantly improves performance in urban expressway merging zones and provides a valuable reference for advancing CAV safety and comfort in intelligent, connected environments.

Keywords: traffic engineering; lane change decision-making; deep reinforcement learning; CAV; lane change risk assessment; expressway merging area

Received 31 May 2024

Funding: Fundamental Research Funds for the Central Universities (2572023CT21); National Natural Science Foundation of China (52378433); Key Research and Development Program of Heilongjiang Province (JD22A014)

* Corresponding author. *E-mail address*: guozhucheng@126.com.

https://doi.org/10.19721/j.cnki.1001-7372.2025.01.019

0 引　言

城市快速路作为高运量、长距离的交通走廊，其合流区汇集主路和匝道车流，换道冲突频率和严重程度显著高于其他路段[1-2]。在智能网联环境下，主路车辆与匝道车辆间的车速差异、交通流量的高密度特征，以及对道路空间优先使用权的竞争，使得合流区的交通调度更加复杂，要求车辆在换道过程中不仅要有效避免碰撞，还需实现空间和时间上的精确协调。随着自动驾驶技术的迅速发展，道路交通系统的智能化、网联化和协同化转型为提升城市快速路通行安全和效率提供了坚实的技术基础，智能网联车辆(Connected Autonomous Vehicle, CAV)的研究成果集中于车辆换道决策、协同巡航控制及车辆跟驰等方面。其中，深度强化学习(Deep Reinforcement Learning, DRL)极大地推动了自动驾驶决策技术的发展[3]。然而，由于城市快速路合流区的特殊性和复杂性，换道难度更高，对车辆的感知、决策以及实时性提出了更为严苛的要求[4-5]。因此，本文旨在考虑城市快速路合流区的换道特征，提出潜在换道风险的动态评估方法，并利用深度强化学习建立融入风险意识的 CAV 换道决策模型，可为解决快速路合流区的交通安全问题提供新的方法及思路。

在智能网联技术的突破进程中，精确评估换道风险对于优化行车安全和效率至关重要，有学者利用高精度轨迹数据深入分析了车辆运行风险的微观机制，为智能网联环境下的车辆风险评估提供了研究的重要先决条件。Huang 等[6]根据自车与周围车辆的空间位置及行驶状态，提出一种融合换道意图识别与风险评估的行驶风险评估架构。Gan 等[7]基于换道全过程轨迹数据集，建立了一种行驶时空变化效应的关系模型。Li 等[8]利用微观轨迹数据集，采用代替安全措施评估车辆行驶潜在冲突风险。基于此，国内外研究学者提出多种交通冲突指标广泛应用于 CAV 换道风险评估领域，如 Park 等[9]利用换道期间停车距离(Stopping Distance Index, SDI)的连续分布特性，探索了换道车辆与邻车的行

中国知网　https://www.cnki.net

驶交互作用，而 Zhang 等[10]根据换道过程冲突类型及其碰撞时间（Time To Collision，TTC），对换道风险进行了全面评估。此外，还有学者关注车辆换道行为特性，探索时空分布特征下的内在机理，并建立安全换道准则，王慧然等[11]利用安全态势划分方法分析换道过程横向运动特征，设计了换道决策准则；谢济铭等[12]利用安全风险去判断换道时机，并基于换道频率 Gaussian 分布模型提出了多步决策规则。

近年来，针对车辆驾驶行为决策算法的研究取得了显著进展，换道决策领域研究主要集中于 3 个内容：基于决策规划、风险评估以及基于深度学习的方法[13-15]。Huang 等[16]采用人工势场方法进行势函数赋值并采用局部电流比较方法寻找无碰撞路径。部分学者进一步将车辆动力学融入规划研究中，冯付勇等[17]提出了一种基于图卷积网络和二次规划的智能车辆自主换道行为决策与运动规划方法。基于风险评估的方法则侧重于评估车辆在换道过程中的潜在风险，并以此为依据制定安全策略。Glaser 等[18]提出的算法可在低计算能力的故障安全嵌入式环境中运行，确保了在资源受限情况下的换道安全性。Wang 等[19]将潜在的碰撞严重程度和人工势场结合到控制器目标中，实现了模块化的风险控制，提高决策的安全性和灵活性。学者们也经常使用特定的安全指标来评估风险，Kim 等[20]提出了一种基于对周围车辆的未来轨迹威胁预测算法，可以在更长的时间范围内准确预测 TTC。DRL 结合了深度学习和强化学习的优势，通过在动态环境中学习与优化，使自动驾驶系统能够在复杂交通场景中做出最优决策，近年来在自动驾驶决策中得到了广泛应用。Shen 等[21]通过将换道过程分解为决策和运动，采用双层深度强化学习架构，提高了变道的安全性和效率。学者蔺庆海等[22]将匝道协同控制转化为马尔科夫决策过程，并融合单步和全局的奖励函数，优化了整个换道过程的协同性和稳定性。谷梦路等[23]提出了一种融合随机森林算法和深度 Q 网络算法的 CAV 汇入控制模型，实现了 CAV 汇入决策和纵向加速度控制的融合。罗鹏等[24]建立专家规则库优化 DQN 网络结构进行换道决策。尽管 DRL 在自动驾驶决策中表现出色，但当前许多基于 DRL 的策略在实际应用中尚未充分考虑到运行安全问题，使其在面对高风险场景时具有局限性。为进一步考虑运行安全，Dávid 等[25]基于神经网络评估动态可用操作的风险以实现期望换道决策；Li 等[26]通过概率模型的风险评估方法，使用 DRL 提出了一种风险感知决策算法，找到期望风险最小的策略。

综上所述，换道风险量化与评估方法主要包括安全代替措施和安全态势评估等。其中，现行经典 TTC 指标将车辆视为质点，忽略了换道车辆与邻车之间的时空重叠区域，而该区域可能存在潜在运行风险。这种简化可能导致风险评估不够全面，尤其在复杂的换道场景中更为明显。此外，在换道决策过程中，现有 DRL 算法在换道过程主要侧重于换道效率的提升，然而在安全性方面的考虑仍有不足，亟需结合实时动态风险评估来进一步优化。为解决上述问题，本研究提出了融入换道风险动态评估的城市快速路合流区 CAV 决策模型研究。通过实时计算换道碰撞时间（Lane Change Time to Collision，LCTTC）进行换道风险动态评估，综合考虑行车安全性、高效性、舒适性及稳定性等方面，建立多维度奖励结构，提出具有风险感知的 SIDQN（Security Improvement Deep Q-Network）换道策略，为智能网联环境下的换道决策提供了更加全面、可靠的解决方案。

1 CAV 换道风险动态评估方法

1.1 研究框架

在城市快速路合流区，CAV 如何实现更加安全、舒适和高效的换道决策是一个关键问题。在融入场景初期，CAV 尚无法自主进行换道，需要通过自主训练学习来逐步优化其换道决策。换道过程中的风险评估是确保 CAV 安全换道的有效手段，因此，城市快速路合流区的 CAV 换道风险评估方法也是本文研究的核心内容之一。

传统的 TTC 冲突指标是在假设车辆为点的基础上提出的[9]，并未考虑车辆实体空间下的交叉轨迹区域及该在区域内存在的潜在风险问题。合流区换道风险量化的整体思路为：在换道决策模型训练过程中，实时获取换道 CAV 及其邻车（CAV 原车道前车、CAV 原车道后车、CAV 目标车道前车和 CAV 目标车道后车）的详细轨迹数据；通过二维空间矩形化车辆个体，确定时间步长内换道车辆与邻车是否具有时空重叠，若存在时空重叠，则说明可能存在潜在风险，若不存在则车辆交互安全；然后，计算时空重叠车辆之间的换道碰撞时间（Lane Change Time to Collision，LCTTC），将 T 作为换道车辆与邻车的潜在冲突风险值，得到换道风险动

中国知网 https://www.cnki.net

态评估结果，其流程如图 1 所示。

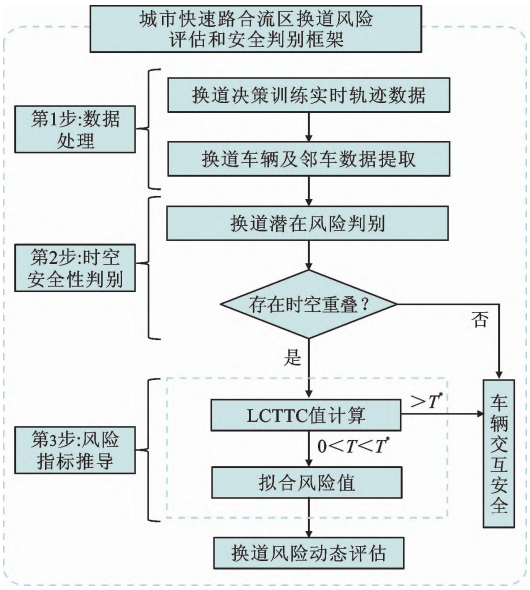

图 1　安全判别和风险评估框架

Fig. 1　Safety Discrimination and Risk Assessment Framework

1.2　时空重叠分析

为保障时空一致性分析的精确性，将研究聚焦于换道车辆 A 及其同帧紧邻的邻车（目标车道前车 B、后车 C，以及原车道前车 D、后车 E）。当两辆车在同一时间点占据相同空间位置时出现碰撞，且碰撞过程始于车辆表面的初次接触，随后发展为全面的挤压碰撞。因此，在深入分析换道车辆的潜在冲突时，必须考虑车辆的尺寸特性。图 2 展示了车辆轨迹在二维平面上的相交情况，虚线轨迹与箭头分别指示了车辆的行驶路径与方向，重叠部分为冲突区。

为了深入探究车辆是否同步趋近潜在的冲突区域，以图 3 为例进行分析，其中车辆 A 和 B 的质心位置坐标为(x_1, y_1)、(x_2, y_2)，速度分别为 v_1、v_2。

对于车辆 A

$$\left.\begin{aligned} &\tan(r)=v_{1x}/v_{1y} \\ &v_1=\sqrt{v_{1x}^2+v_{1y}^2} \\ &r=\arctan(v_{1x}/v_{1y}) \end{aligned}\right\} \tag{1}$$

车辆 B 生成同方向速度 v_2

$$v_2=\begin{cases} v_{2y}\cos(r)+v_{2x}\sin(r) \\ \sqrt{v_{2x}^2+v_{2y}^2} \end{cases} \tag{2}$$

因此，车辆 A、B 的相对速度为

$$\overrightarrow{\Delta v}=\overrightarrow{v_1}-\overrightarrow{v_2} \tag{3}$$

将车辆轮廓进行矩形化，每辆车利用 8 个点进行定位，选择车辆 A、B 的任一点位相连接，如图 3

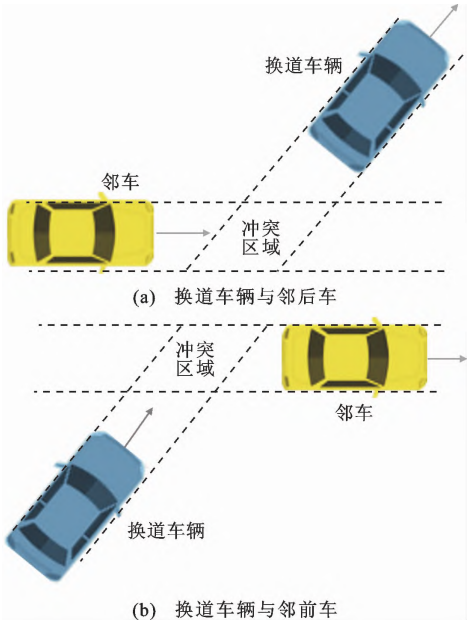

图 2　换道冲突区域

Fig. 2　Conflict Zones of Lane Change

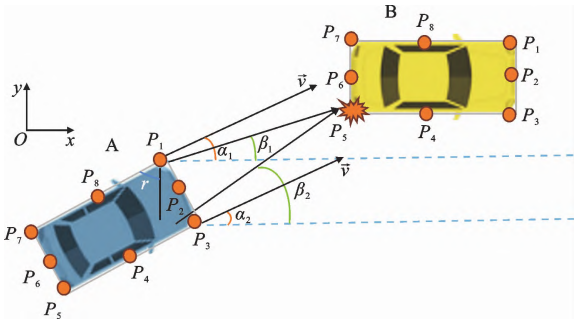

图 3　车辆的相对位置

Fig. 3　Relative Position of the Vehicle

中的车辆 A(P_1)点位和车辆 B(P_5)点位，(Δx_1，Δy_1)为两点位的位置坐标差值，定义$\overrightarrow{\Delta v}$与横轴形成的角为 α_1。

$$\left.\begin{aligned} &\frac{\Delta y_1}{\Delta x_1}=\tan(\beta_1) \\ &\beta_1=\arctan\frac{\Delta y_1}{\Delta x_1} \\ &\theta_1=\alpha_1-\beta_1 \end{aligned}\right\} \tag{4}$$

车辆 A(P_1)点位与 A(P_3)构成组合，针对 A(P_3)、B(P_5)两车的相对速度$\overrightarrow{\Delta v}$与 x 轴形成的角为 α_2，实际 $\alpha_1=\alpha_2$，(Δx_2，Δy_2)为 A(P_3)、B(P_5)两点位的位置坐标差值。

$$\left.\begin{aligned} &\frac{\Delta y_2}{\Delta x_2}=\tan(\beta_2) \\ &\beta_2=\arctan\frac{\Delta y_2}{\Delta x_2} \\ &\theta_2=\alpha_2-\beta_2 \end{aligned}\right\} \tag{5}$$

中国知网　https://www.cnki.net

通过上述时空重叠分析，引入中值定理如下

$$\theta_1<0\cap\theta_2>0\Rightarrow\exists\theta:\theta_1<\theta<\theta_2\cap\theta=0 \tag{6}$$

在图 3 的情况下，θ_1 和 θ_2 异号，依据中值定理，可以断定在车辆 A 必存在一个特定位置，使得 $\theta_1\theta_2=0$，车辆此时处于非安全状态。基于此，于车辆 A 中任意选取两点，并与车辆 B 中的任一点位构成特定几何关系，使得 $\theta_1\theta_2<0$，即车辆 A 这 2 个点位之间必然存在一点与车辆 B 发生碰撞。若车辆间所有的点位组合都有 $\theta_1\theta_2>0$，意味着不存在碰撞。

1.3 考虑紧邻多车信息的 LCTTC 计算

经典 TTC 理论[9]通常将车辆运行描述为一维问题，合流区车辆需在有限距离内驶入主线，因此与紧邻多车的时空重叠情况更加复杂。同时，主线与匝道连接处具有展宽渐变段，故导致进行多车交互的冲突分析存在角度遗漏，从而无法准确反映换道过程中潜在的运行风险。为准确描述城市快速路合流区域潜在换道风险，本文进一步提出 LCTTC 理论，考虑到换道场景下 CAV 与紧邻多车的时空重叠情况，关注车辆换道与决策行为的矢量关系，分析合流区换道场景下存在的潜在冲突形式，更为准确地量化车辆行车风险。若 CAV 与邻车交互过程中存在时空重叠则计算 LCTTC 值，得到 CAV 的动态风险评估结果，车辆矢量位置与速度关系如图 4 所示。

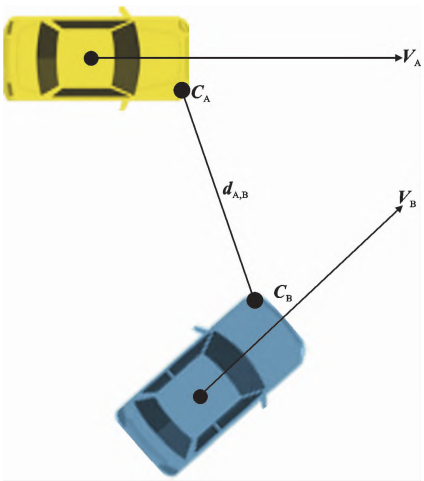

图 4 车辆矢量位置与速度关系

Fig. 4 Relationship Between Vehicle Vector Position and Velocity

根据图 4，假设车辆 A 的位置向量为 $\boldsymbol{C}_A=(X_A,Y_A)$，而车辆 B 的位置向量为 $\boldsymbol{C}_B=(X_B,Y_B)$，矢量速度分别为 $\boldsymbol{V}_A$、$\boldsymbol{V}_B$。两车间距离的表达式

$$d_{A,B}=\sqrt{(\boldsymbol{C}_A-\boldsymbol{C}_B)^T(\boldsymbol{C}_A-\boldsymbol{C}_B)} \tag{7}$$

考虑到换道时车道、方向、时间的不均衡性与随机性，通过对换道车辆 A 与邻车 B、C、D、E 的轮廓坐标进行点位搜索过程，求解最近点之间的距离 $d_{A,B}$、$d_{A,C}$、$d_{A,D}$、$d_{A,E}$。应用向量求导的乘法规则和链式法则，得到两辆车相撞的相对速度又叫做车辆的接近率。

$$d'_{A,B}=\frac{1}{d_{A,B}}(\boldsymbol{C}_A-\boldsymbol{C}_B)^T\cdot(\boldsymbol{V}_A-\boldsymbol{V}_B) \tag{8}$$

假设车辆质心速度与各点位速度相同，易得车辆 A 与 B、C、D、E 的接近率分别为 $d'_{A,B}$、$d'_{A,C}$、$d'_{A,D}$、$d'_{A,E}$。

$$\left.\begin{aligned}
d'_{A,B}&=\frac{1}{d_{A,B}}(\boldsymbol{C}_A-\boldsymbol{C}_B)^T\cdot(\boldsymbol{V}_A-\boldsymbol{V}_B)\\
d'_{A,C}&=\frac{1}{d_{A,C}}(\boldsymbol{C}_C-\boldsymbol{C}_A)^T\cdot(\boldsymbol{V}_C-\boldsymbol{V}_A)\\
d'_{A,D}&=\frac{1}{d_{A,D}}(\boldsymbol{C}_A-\boldsymbol{C}_D)^T\cdot(\boldsymbol{V}_A-\boldsymbol{V}_D)\\
d'_{A,E}&=\frac{1}{d_{A,E}}(\boldsymbol{C}_E-\boldsymbol{C}_A)^T\cdot(\boldsymbol{V}_E-\boldsymbol{V}_A)
\end{aligned}\right\} \tag{9}$$

LCTTC 表示固定步长下换道车与邻车间的最小时间间隔，可为分析车辆动态交互量化依据。因此，可假设车辆接近率恒定，由定义可知 $d_{A,B}+d'_{A,B}T=0$，其中 T 为 LCTTC 值，得出两车相撞时的 LCTTC 为

$$\left.\begin{aligned}
T_B&=-\frac{d_{A,B}}{d'_{A,B}}=-\frac{(\boldsymbol{C}_A-\boldsymbol{C}_B)^T\cdot(\boldsymbol{C}_A-\boldsymbol{C}_B)}{(\boldsymbol{C}_A-\boldsymbol{C}_B)^T\cdot(\boldsymbol{V}_A-\boldsymbol{V}_B)}\\
T_C&=-\frac{d_{A,C}}{d'_{A,C}}=-\frac{(\boldsymbol{C}_C-\boldsymbol{C}_A)^T\cdot(\boldsymbol{C}_C-\boldsymbol{C}_A)}{(\boldsymbol{C}_C-\boldsymbol{C}_A)^T\cdot(\boldsymbol{V}_C-\boldsymbol{V}_A)}\\
T_D&=-\frac{d_{A,D}}{d'_{A,D}}=-\frac{(\boldsymbol{C}_A-\boldsymbol{C}_D)^T\cdot(\boldsymbol{C}_A-\boldsymbol{C}_D)}{(\boldsymbol{C}_A-\boldsymbol{C}_D)^T\cdot(\boldsymbol{V}_A-\boldsymbol{V}_D)}\\
T_E&=-\frac{d_{A,E}}{d'_{A,E}}=-\frac{(\boldsymbol{C}_E-\boldsymbol{C}_A)^T\cdot(\boldsymbol{C}_E-\boldsymbol{C}_A)}{(\boldsymbol{C}_E-\boldsymbol{C}_A)^T\cdot(\boldsymbol{V}_E-\boldsymbol{V}_A)}
\end{aligned}\right\} \tag{10}$$

式中：T_B、T_C、T_D、T_E 分别为换道车辆 A 与邻车 B、C、D、E 的 LCTTC 值。考虑当 $d'_{A,B}>0$ 时，意味着后车速度比前车速度更快，两车之间的距离减小，可能发生碰撞。

2 强化学习及换道决策模型

2.1 强化学习

2.1.1 深度强化学习 DQN

DRL 是一种深度学习和强化学习的融合方法，广泛应用于人工智能领域。它通过马尔科夫决策过程(Markov Decision Process，MDP)来形式化描述智能体与环境的交互。其核心思想是通过智能体与

中国知网 https://www.cnki.net

环境交互，不断积累奖励并以此为目标，通过试错找到最优的决策策略。在该过程中，智能体使用深度神经网络对其决策策略进行近似和优化，从而能够自动应对复杂的交通环境问题。MDP 模型包含状态、动作及奖励，表示为(s,a,r)，即在状态 s 下采取行动 a，得到奖励值 r。寻求最优策略 τ^* 如式(11)，其中奖励的折扣因子 $\gamma\in(0,1]$，控制未来奖励的权重。

$$\tau^*(s)=\underset{\tau}{\operatorname{argmax}}E_\tau\left(\sum_{k=0}^{+\infty}\gamma^k r_{t+k}\mid s_t=s\right)\tag{11}$$

为简化求解，引入 Q 值函数来表示期望累计奖励，通过最大化 Q 值寻求最优策略

$$\left.\begin{aligned}&Q^\tau(s,a)=E_\tau\left(\sum_{k=0}^{+\infty}\gamma^k r_{t+k}\mid s_t=s,a_t=a\right)\\&Q^*(s,a)=\max_a Q^\tau(s,a)\end{aligned}\right\}\tag{12}$$

DQN 是强化学习的深度版本[27]，采用深度神经网络来近似Q值函数。它使用2个神经网络进行 Q 值估算，分别是 Q_{target}，Q_{online}。在训练过程 Q_{online} 会生成一系列四元组 s_t,a_t,r_t 和 s_{t+1}，将其存储在经验重放池中，通过随机采样减少数据间的相关性。DQN 的损失函数基于 Q 值函数的时间差分(Temporal Difference, TD)误差，定义为

$$L=E_{(s,a,r,s')\sim D}[(y-Q(s,a,\theta))^2]\tag{13}$$

式中：(s,a,r,s')为从回放记忆库 D 获取的随机样本；y 为目标 Q 值，其表示为

$$y=r+\gamma\max_{a'}Q(s',a',\theta')\tag{14}$$

式中：θ、θ' 分别为 Q_{online}、Q_{target} 的网络参数；Q_{target} 通过固定时间步复制 Q_{online} 参数，避免频繁更新导致的发散问题。

2.1.2　其他算法

DQN 使用双重网络来实现函数逼近，有效地提高了网络的稳定性，并用经验回放降低了数据相关性。在此基础上还有 3 种优化算法，可用于测试本文策略的效果，具体介绍如表 1 所示。

表 1　其他算法介绍

Table 1　Introduction of Other Algorithms

算法名称	公式	优势
双深度 Q 网络(Double Deep Q-Network，DDQN)[28]	$y=r+\gamma Q(s',\max_{a'}Q(s',a',\theta),\theta')$	在 DDQN 中，动作选择由在线网络 Q_{online} 负责，动作评估则由目标网络 Q_{target} 负责。1. 减少过度估计问题；2. 提高训练稳定性；3. 更快收敛。
竞争深度 Q 网络(Dueling DQN，DulDQN)[29]	$Q(s,a,\theta)=V(s,\theta)+\left(A(s,a,\theta)-\frac{1}{\lvert A\rvert}A(s,a',\theta)\right)$	在 DulDQN 中，确保 Q 值函数能够更好地解耦状态价值和动作优势。1. 更好的状态价值评估；2. 优势函数的去中心化；3. 提升学习效率。
优先级经验回放深度 Q 网络(DQN with Prioritized Replay，PRDQN)[30]	$\delta_i=\lvert r_i+\gamma\max_{a'}Q(s',a',\theta')-Q(s_i,a_i,\theta)\rvert$ $P(i)=\frac{\delta_i^\alpha}{\sum_j\delta_i^\alpha}$	在 PRDQN 中，通过引入 TD 误差来确定样本的重要性，极大提高了 DQN 的学习效率。1. 加速学习；2. 提高数据效率；3. 减少训练样本的浪费。

注：$V(s,\theta)$为价值函数；$A(s,a,\theta)$为优势函数部分；$|A|$为动作空间的大小；$P(i)$表示第 i 个样本被抽中的概率；δ 为样本的 TD 误差。

2.2　换道决策模型

本文聚焦于城市快速路合流区的 CAV 换道问题，充分考虑合流区场景下的潜在风险，利用安全改进 DQN 算法来指导 CAV 学习有效的换道决策，并制定针对换道决策的 DRL 配置，即状态空间、动作空间和奖励函数。合流区 CAV 与邻车的互动场景如图 5 所示。

2.2.1　状态空间

CAV 行驶过程对于环境做出的相应定量动作被叫做状态空间，在换道决策时将会受到邻车运行信息的干扰。在本文中，对于换道 CAV 车辆的邻车描述为 V_{nc}，其中 n 为邻车相对于换道 CAV 的车道位置，$n\in\{\text{g},\text{o}\}$，g 表示目标车道，o 表示原车道；$c$ 表示邻车相对于换道 CAV 的前后位置，$c\in\{\text{f},\text{r}\}$，f 表示前向，r 表示后向。将换道决策问题的状态空间定义为 S，其表示如下

$$S=\{S_{V_{\text{CAV}}},S_{V_{\text{g-f}}},S_{V_{\text{g-r}}},S_{V_{\text{o-f}}},S_{V_{\text{o-r}}}\}\tag{15}$$

式中：$S_{V_{\text{CAV}}}$ 和 $S_{V_{n\text{-}c}}$ 分别为智能车辆以及周围车辆的状态信息，定义为

$$\left.\begin{aligned}&S_{V_{\text{CAV}}}=\{\boldsymbol{v}_{\text{CAV}},\boldsymbol{a}_{\text{CAV}}\}\\&S_{V_{n\text{-}c}}=\{\boldsymbol{v}_{V_{n\text{-}c}},\boldsymbol{a}_{V_{n\text{-}c}},\boldsymbol{x}_{V_{n\text{-}c}}\}\end{aligned}\right\}\tag{16}$$

式中：$\boldsymbol{v}$ 为车辆的速度；$\boldsymbol{a}$ 为车辆加速度；$\boldsymbol{x}$ 为邻车相对于智能车辆的纵向距离。

2.2.2　动作空间

换道决策的目的是让 CAV 通过换道行为避开前方行驶较慢的车辆，以获得更高的速度，但同时需

中国知网　https://www.cnki.net

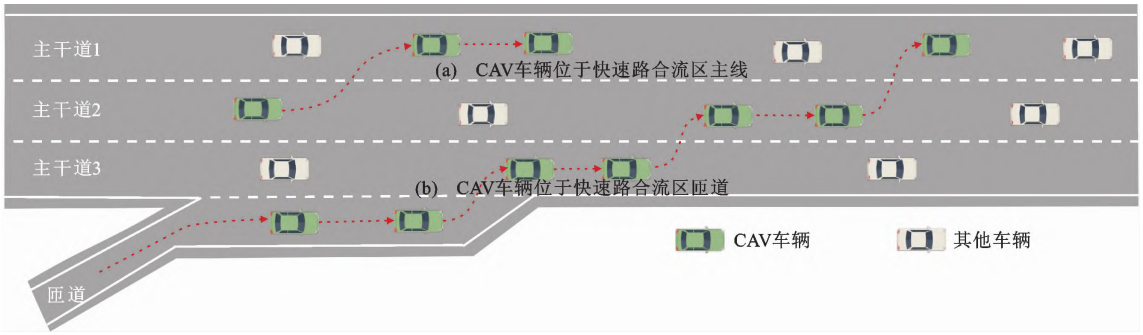

图 5 快速路合流区换道场景

Fig. 5 Lane Change Decision Scenario in the Merging Area of an Expressway

要考虑换道车辆两侧车道的邻车，若有潜在风险则速度动态变化。本文换道决策动作为狭义的行为决策，因此将动作空间定义为 A，其表示如下

$$A=\{c_l,c_r,s_u,s_d,s_k\} \tag{17}$$

式中：c_l、c_r 为向左、向右转；s_u 为增加纵向速度，通过加速，CAV 可以更快地避开前方较慢的车辆，提升整体行驶效率；s_d 为减少纵向速度，通过减速，CAV 可以与前方车辆保持安全距离，避免潜在碰撞；s_k 为保持当前纵向速度不变，CAV 继续以当前速度行驶，适用于前方没有障碍物或慢速车辆的情况。

2.2.3 快速路合流区奖励函数设计

城市快速路合流区的场景中，CAV 的主要目标是以安全、快速且舒适的方式通过合流区。因此，对奖励机制的设计框架从以下几个维度设计：

R_v：速度奖励，主车速度 v_{CAV} 与目标车道前车的速度 v_{FGV} 之比。考虑换道安全，采用最小安全距离模型评估。若不满足安全条件，则速度奖励的折扣因子为 0，引导车辆保持安全跟驰

$$R_v=v_{CAV}/v_{FGV} \tag{18}$$

R_{d1}：即面向前车的可接受减速度奖励机制。当目标车道前方车辆位于影响主车的特定距离阈值内时，主车可接受减速度 d_{CAV} 与目标车道前车减速度 d_{FGV} 之比

$$R_{d1}=d_{CAV}/d_{FGV} \tag{19}$$

R_{d2}：即面向后车的可接受减速度奖励机制。当目标车道后方车辆位于影响主车的特定距离阈值内时，主车可接受减速度 d_{CAV} 与目标车道后车减速度 d_{RGV} 之比

$$R_{d2}=d_{CAV}/d_{RGV} \tag{20}$$

R_{sd}：安全距离奖励。换道临界间隙 s_{CG} 与行驶安全距离 s_{safe} 之比

$$R_{sd}=s_{CG}/s_{safe} \tag{21}$$

R_{LCTTC}：风险意识奖励。换道期间若判别换道车辆与邻车具有时空重叠，考虑换道车辆与邻车 LCTTC 的 T 大小，其中 T^* 为风险临界值[31]

$$R_{LCTTC}=\frac{T-T^*}{T^*} \tag{22}$$

R_{d1} 和 R_{d2} 依据 Gipps 模型[32]评估换道安全性，考量换道所需减速度是否超限，构建减速度模型以量化分析，其计算公式为

$$d_n=[2-(D-x_n(t))/(10v_n)]d_n^* \tag{23}$$

式中：d_n 为车辆 n 在 t 时刻可接受的减速度；D 为预定的转向或障碍物的位置；x_n 为车辆 n 在 t 时刻的位置；v_n 为车辆 n 的期望速度；d_n^* 是一般情况下车辆愿意接受的减速度。

折扣因子 λ 为平衡奖励权重，目标车辆行驶决策的奖励具体形式为

$$R_t=\lambda_v R_v+\lambda_{d1}R_{d1}+\lambda_{d2}R_{d2}+\lambda_{sd}R_{sd}+\lambda_{LCTTC}R_{LCTTC} \tag{24}$$

为促进神经网络的高效运算，设计多重偏置项用于惩罚：w_1 用于对车辆碰撞事件施加惩罚，强化安全导向；w_2 作为车辆越界行为的惩戒措施；w_3 针对车辆频繁换道行为，旨在提升乘客乘坐的舒适度与旅程质量；而 w_4 则专门应对车辆逆行与倒车等严重违规行为，具体形式为

$$Q_{value}(R_v,R_{d1},R_{d2},R_{sd},R_{LCTTC},w_1,w_2,w_3,w_4)=\lambda_v R_v+\lambda_{d1}R_{d1}+\lambda_{d2}R_{d2}+\lambda_{sd}R_{sd}+\lambda_{LCTTC}R_{LCTTC}+w_1+w_2+w_3+w_4 \tag{25}$$

当目标车辆位于匝道时，需在合流区展宽终止线前完成一次换道，否则将引发拥堵。因此，该情景下不考虑 CAV 与目标车道前车之间的速度关系，且仅需设置偏置项 w_1，w_3，w_4，具体形式为

$$Q_{value}(R_{d1},R_{d2},R_{sd},R_{LCTTC},w_1,w_3,w_4)=\lambda_{d1}R_{d1}+\lambda_{d2}R_{d2}+\lambda_{sd}R_{sd}+\lambda_{LCTTC}R_{LCTTC}+w_1+w_3+w_4 \tag{26}$$

综上，本文通过从高效性、舒适性和安全性多个维度综合设计奖励函数，以确保 CAV 在快速路合流区换道时的决策优化。

中国知网 https://www.cnki.net

2.2.4　算　法

在城市快速路场景中，CAV 在不同道路环境的状态 s_t 下将选择不同的驾驶行为 a_t，每个驾驶行为得到相应的奖励或惩罚 r_t，使得目标车辆进入下一个状态 s_{t+1}，以此循环往复得到最优的驾驶决策，其中，状态 $s_t \in S$，行为 $a_t \in A$，奖励 $r_t \in R_t$。

考虑融入风险意识的 SIDQN 换道决策算法如下：

输入：状态 S

初始化：

(1)初始化回放记忆库 D，容量为 N。

(2)设置学习率、折扣因子、总训练步数及更新频率。

训练过程：

(1)环境获取初始状态。

(2)根据 ε-greedy 策略选取动作 A。

(3)执行动作 a_t，得到奖励 r_t 和下一个状态 s_{t+1}。

(4)存储经验，将 (s_t, a_t, r_t, s_{t+1}) 添加到回放记忆库 D。

(5)回放记忆库判断，如果数据数量达到 N，则进行以下步骤：

①从回放记忆库 D 中随机抽取批量数据；

②更新当前网络的参数，定期更新目标网络参数。

(6)安全模块

①轨迹预测：预测目标车辆在当前状态下可能的轨迹；

②风险评估：根据预测的轨迹和周围车辆的状态，评估当前动作的风险值；

③动作剪裁：根据风险值调整动作选择策略，避免高风险动作；

④奖励函数：在计算奖励时融入风险评估结果，进一步优化奖励函数。

循环迭代：

(1)状态更新。

(2)更新步数计数器。

(3)迭代终止条件：判断迭代次数是否达到总训练步数 T，如果未达到则重复上述步骤；否则训练结束。

算法流程如图 6 所示。

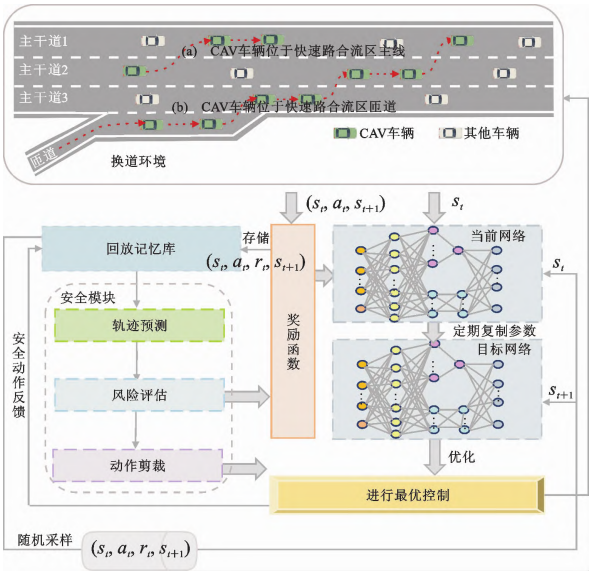

图 6　DRL 算法流程

Fig. 6　Flow Chart of the DRL Algorithm

3　仿真试验验证

3.1　仿真环境搭建

为了验证本文 CAV 换道决策的可行性，基于城市快速路建设规范，使用 Python 软件依托 Highway-env 自动驾驶决策仿真平台搭建快速路合流区仿真试验环境，快速路合流区车道设置参数如表 2 所示。

表 2　快速路合流区车道设置

Table 2　Lane Setting in Merging Area of Expressway

设置项	设置值	设置项	设置值
主线车道数量	3	合流区长度/m	80
匝道车道数量	1	单车道宽度/m	3.5
试验车道总长度/m	510	主路限速/(km·h^{-1})	80
试验部分匝道长度/m	150	匝道限速/(km·h^{-1})	40

本文采用智能驾驶人模型(Intelligent Driver Model，IDM)来控制环境车辆纵向，最小化由换道引起的所有制动(Minimizing Overall Braking Induced by Lane Changes，MOBIL)模型进行横向换道[33]，尽可能还原混合交通场景，为简化研究参照文献[34]对车辆特征及运行模型的参数进行标定，其他参数如表 3 所示。

表 3　车辆参数设置

Table 3　Vehicle Parameter Setting

设置项	设置值	设置项	设置值
车辆长度/m	5	舒适减速度/(m·s^{-2})	2
车辆宽度/m	1.8	期望速度/(km·h^{-1})	80
最大加速度/(m·s^{-2})	1.4		

3.2　奖励函数参数设置

在设计 SIDQN 算法神经网络架构时，需依据问题特性进行构建，旨在通过优化诸如学习率等关键参数，来增强算法的学习效能。参考文献[35]、

中国知网　https://www.cnki.net

[36]，构建了包含两隐层（每层 256 神经元）的网络。通过调整学习率控制权重更新，利用经验回放缓冲区存储经验，并集成 Tensor Board 监控训练。具体参数设定值如表 4 所示。

表 4 神经网络参数设置

Table 4 Neural Network Parameter Setting

参数名称	标定值	参数名称	标定值
学习率	0.000 4	更新网络步数	1
回放记忆库大小	15 000	更新网络次数	1
学习前预热步数	200	训练过程控制参数	1
样本数量	32	网络更新频率	50

3.3 试验方案

3.3.1 对比策略

在开源自动驾驶仿真场景 Highway-env 中，为设置测试对比，选取网络结构与本文细化决策子模块相同的原 DQN 算法[24]，配置的奖励函数主要侧重于 3 个关键目标：提升目标 CAV 的速度，尽量保持在最右侧车道行驶，并避免与其他车辆发生碰撞，以下简称 DQN 策略；而在安全改进 DQN 算法下，奖励函数在原有 DQN 策略奖励下进一步考虑了提供舒适的减速度，并减少目标 CAV 的频繁换道和加减速行为，同时确保目标 CAV 与其他车辆之间保持安全的行驶距离，进一步融入动态风险评估结果，综合考虑了效率、安全和舒适性以期达到更为优化的换道决策效果，称为 SIDQN 策略。此外，本文还对 DDQN、DulDQN、PRDQN 三种 DRL 算法进行对比分析。

3.3.2 训练过程

针对目标 CAV 在合流区的不同位置，设置了不同的起始速度，整个仿真的总时长设定为 30 s，在这段时间内持续记录仿真运行的数据。训练所使用的 CPU 为 i7-13650HX，显卡为 NVIDIA GeForce RTX 4060，操作系统为 Windows 11，5 种策略下（DQN、SIDQN、DDQN、DulDQN、PRDQN）训练 1×10^8 回合，每个回合起始于目标 CAV 进入试验路段起点，终止于目标 CAV 到达试验路段终点，完成所有迭代后将获得适应不同策略的神经网络模型。

图 7 展示了多种策略随着训练回合的推进奖励值变化情况，横轴每个节点代表模型训练了 2×10^6 次。由图 7 可知，训练过程中，5 种策略的奖励值在训练初期（前 30% 的训练回合）均呈现增长趋势。DQN 策略奖励值在训练回合数增加后稳定在较低水平；相比 DQN 策略，DDQN 策略的奖励值更高，

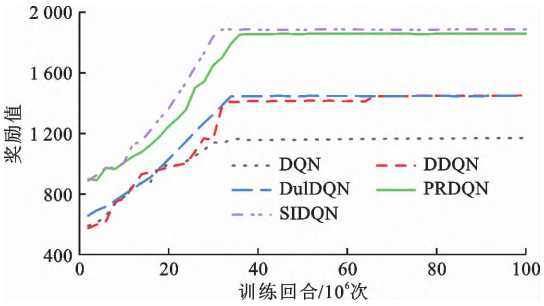

图 7 不同策略训练过程的奖励情况

Fig. 7 Reward Conditions During Training Processes of Different Strategies

但波动性较强，模型稳定性较差，最后保持稳定的奖励值与 DulDQN 策略处于同一水平；SIDQN 和 PRDQN 策略结果均较为突出，表现出较好的稳定性和收敛性。

3.4 试验结果分析与对比

为确保模型的泛化能力和一致性表现，本研究在神经网络训练完成后，设计并实施了城市快速路合流区场景仿真试验。为确保试验结果的可靠性，更改不同随机数种子，在多种策略下均开展 5 组独立试验，并采用平均值作为最终仿真结果。

3.4.1 行车效率分析

车速反映动态交通流情况，其分布和变化趋势能够揭示交通流的稳定性和连续性，因此对车速进行分析可以较好地分析换道决策下的运行效率。通过随机试验数据采集，多种策略下的目标车辆仿真过程速度均可较快达到目标速度，故不进行对比分析，结果如图 8 所示。

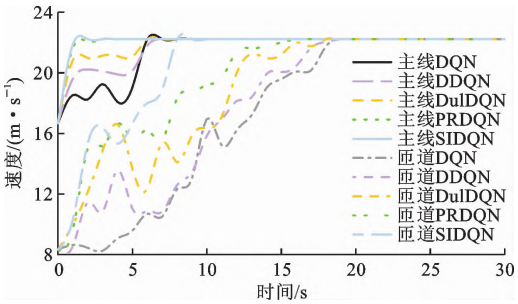

图 8 不同策略下的车辆速度

Fig. 8 CAV Vehicle Speed Under Different Strategies

行车效率还可通过目标车辆换道成功率以及行驶过程中的平均速度大小进行对比分析，表 5 为各策略目标 CAV 的换道成功率以及运行平均速度数据。从平均速度来看，SIDQN 策略和 PRDQN 策略表现最优，显著高于其他策略，表明这 2 种策略在提高车辆运行效率上具有优势。相比之下，DQN 策略

中国知网 https://www.cnki.net

表 5　不同策略的行车效率对比

Table 5　Comparison of Driving Efficiency Under Different Strategies

策略	平均速度/(m·s^{-1})	换道成功率/%
DQN 策略	16.935	83.658
DDQN 策略	18.368	79.750
DulDQN 策略	19.842	86.339
PRDQN 策略	20.747	92.120
SIDQN 策略	21.008	95.556

的平均速度最低仅为 16.935 m·s^{-1}，说明其换道决策对行车效率提升有限。换道成功率方面，SIDQN 策略依然表现突出，达到 95.556%，显著优于其他对比策略。以上结果表明本文模型在复杂交通环境下具备更高的决策可靠性和执行能力，可显著优化 CAV 在合流区的运行效率表现。

3.4.2　安全性分析

车辆的驾驶安全性主要由 LCTTC 和事故率进行衡量，在车辆交互时若存在时空重叠，说明 CAV 与邻车具有潜在换道风险，进而计算该步长下的 T。图 9 为 5 种策略存在潜在风险时的 LCTTC 所出现的比例(指计算 $T<T^{*}$[31]时)。如图 9 所示，DQN 的 LCTTC 占比平均值为 29.26%，这是由于 DQN 缺乏风险评估机制，导致它容易做出过于激进的决策，导致频繁的时空重叠情况；DDQN 通过解耦动作选择和 Q 值估计，减少了过度估计问题，使得其在换道风险场景下表现更加稳健，但在处理较复杂的合流区场景时，DDQN 依然存在潜在的风险隐患；DulDQN 的 LCTTC 占比平均为 18.36%，相比 DQN 和 DDQN 进一步降低，这表明 DulDQN 能够更好地识别出状态的价值，从而做出更安全的换道决策；PRDQN 通过优先级经验回放机制，能够优先学习那些具有较大 TD 误差的样本，进而更快速地识别出潜在的高风险场景，在潜在风险场景下表现得较为优越，特别是在第 2 次试验中，LCTTC 占比最低仅为 11.5%；SIDQN 通过将动态风险评估融入奖励函数，在安全性方面表现最为优越。试验结果显示：SIDQN 的 LCTTC 占比平均值为9.56%，是 5 种策略中最低的，表明能够有效避免潜在的换道风险；特别是在第 5 次试验中，SIDQN 的 LCTTC 占比进一步下降到 7.2%，远低于其他策略，体现出应对复杂换道场景时的安全决策优势。

此外，对每种策略记录事故率如图 10 所示。各模型在整个训练过程中都呈现出事故率逐渐下降的趋势，这表明这些模型在不断学习和适应合流场景

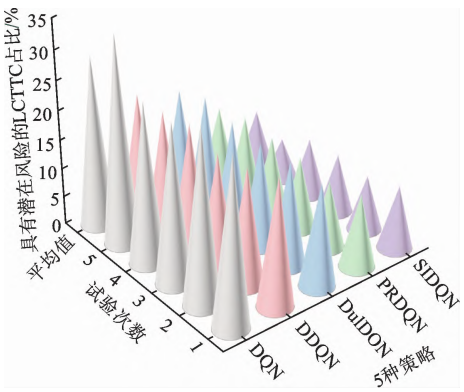

图 9　不同策略下的潜在风险 LCTTC 占比

Fig. 9　Proportion of Potential Risk LCTTC Under Different Strategies

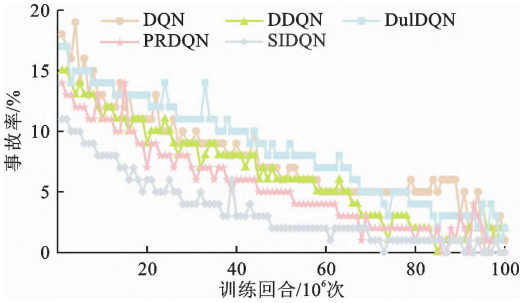

图 10　不同策略的事故率对比

Fig. 10　Comparison of Accident Rates Under Different Strategies

的过程中，安全性能有所提升。初期，DQN 和 DulDQN 模型的事故率明显高于其他模型，事故率在 15%～18%；PRDQN 模型，结合了优先经验回放机制，表现也相当出色，但其事故率的波动性比 SIDQN 稍高一些；尽管 DDQN 在早期结果中表现较为出色，但在大约 20 个回合之后，其事故率降低幅度减小，且明显高于 PRDQN 和 SIDQN；然而，SIDQN 显示出了显著的安全性能优势，初始事故率较低，并且随着回合的推进，事故率持续保持较低水平。总体而言，SIDQN 通过优化的安全性奖励策略，在复杂的交通合流场景中表现出最佳的安全性能。

3.4.3　舒适性分析

在乘坐舒适性方面，对比不同策略的换道次数情况，其中连续换道情况是指 CAV 车辆连续执行 2 次及以上的换道情况，具体数据如表 6 所示。其中，DQN 策略的换道次数最多，且无效换道次数较高，说明其在换道决策中存在一定低效性；相比之下，DDQN 策略表现出优化效果，换道次数减少至 10 次，无效换道次数降至 2 次，但其连续换道次数较高，仍可能影响舒适性；DulDQN 策略进一步降低了

中国知网　https://www.cnki.net

表 6 CAV 运行过程换道次数与极端操作数据统计

Table 6 Statistics of Lane Change Counts and Extreme Maneuver Data During CAV Operation

策略	换道次数	连续换道次数	无效换道次数	极端加速或减速操作次数
DQN 策略	12	2	3	7
DDQN 策略	10	3	2	4
DulDQN 策略	9	2	2	5
PRDQN 策略	5	2	1	2
SIDQN 策略	4	1	1	1

换道次数和无效换道次数，表明其在提高换道决策准确性方面有所改进；PRDQN 策略表现出更为明显的优势，换道次数显著减少至 5 次，且无效换道次数仅为 1 次，显示出其在优化换道效率与稳定性方面的突出表现；SIDQN 策略则表现最佳，换道次数仅为 4 次，连续换道和无效换道次数均为 1 次，表明其在减少不必要换道操作和提高乘坐舒适性方面具备显著优势。

此外，为了进一步评估舒适性，记录极端加速或减速操作的次数（加速度或减速度的绝对值超过3.5 $m \cdot s^{-1}$[37]）。表 6 中极端加减速次数：DQN 策略为 7 次，DDQN 策略为 4 次，DulDQN 策略为 5 次，PRDQN 策略为 2 次，而 SIDQN 策略只出现 1 次。其他 4 种策略相较于 DQN 策略极端操作次数分别减少了 42.86%、28.57%、71.43%、85.71%。综上，相较于其他对比策略，考虑动态风险评估情况的 SIDQN 策略显著降低了频繁换道和极端加速减速操作次数，提升了乘客的舒适体验，在舒适性方面表现最优。

4 结 语

本研究针对 CAV 在快速路合流区的行驶状态及其与周边交通环境的交互，首先，进行交互车辆时空重叠分析，引入 LCTTC 指标，以动态量化和评估 CAV 在换道过程中的潜在风险；综合考虑车辆行驶高效性、安全性及舒适性等因素，提出考虑换道风险动态评估的 CAV 换道决策模型；最后，应用 Highway-env 进行仿真验证试验。主要结论如下：

(1)从时空重叠角度，判别换道 CAV 与邻车是否具有潜在交互风险，研究给出了基于 LCTTC 的换道风险评估方法，实现了风险的动态实时量化。

(2)基于马尔可夫理论改进 DQN 算法，并引入风险意识，综合考虑行车安全性、高效性及舒适性等因素建立多目标奖励函数，提出了混合交通流下城市快速路合流区 CAV 换道决策模型。

(3)利用 Python 开源自动驾驶仿真场景 Highway-env 进行仿真试验，结果表明，本文提出的 SIDQN 策略在模型稳定性、车辆行车效率、安全性分析以及乘客乘车舒适性等方面均优于对比策略。

本文研究成果可为智能网联环境下城市快速路合流区 CAV 安全换道决策研究提供新的方法和思路。论文仍存在不足之处，后续可以从连续换道风险评估及交织区等复杂场景应用等方面展开深入研究。

参考文献：

References：

[1] 吴 勇，孙棣华，李 蕊，等. 快速路合流区交通事故影响因素研究[J]. 中国公路学报，2015，28(9)：98-105.
WU Yong, SUN Di-hua, LI Rui, et al. Study on crash influencing factors at expressway merge segments [J]. China Journal of Highway and Transport, 2015, 28 (9): 98-105.

[2] 张方方，王长君，王俊骅. 城市快速路匝道合流区车辆交互行为模式[J]. 中国公路学报，2022，35(9)：66-79.
ZHANG Fang-fang, WANG Chang-jun, WANG Jun-hua. Vehicle interaction patterns at on-ramp merging area of urban expressway [J]. China Journal of Highway and Transport, 2022, 35 (9): 66-79.

[3] 金立生，韩广德，谢宪毅，等. 基于强化学习的自动驾驶决策研究综述[J]. 汽车工程，2023，45(4)：527-540.
JIN Li-sheng, HAN Guang-de, XIE Xian-yi, et al. Review of autonomous driving decision-making research based on reinforcement learning [J]. Automotive Engineering, 2023, 45 (4): 527-540.

[4] MIN H G, FANG Y K, WU X, et al. On-ramp merging strategy for connected and automated vehicles based on complete information static game [J]. Journal of Traffic and Transportation Engineering: English Edition, 2021, 8 (4): 582-595.

[5] 叶颖俊，孙 剑. 快速路汇入区瓶颈交通流早发性失效研究(第 2 部分)：致因分析[J]. 中国公路学报，2024，37(2)：275-292.
YE Ying-jun, SUN Jian. Early-onset breakdown of bottleneck traffic at expressway merging area, part Ⅱ: Causes analysis [J]. China Journal of Highway and Transport, 2024, 37 (2): 275-292.

[6] HUANG H Y, WANG J Q, FEI C, et al. A probabilistic risk assessment framework considering lane-changing behavior interaction [J]. Science China Information Sciences, 2020, 63 (9): 94-108.

[7] GAN X F, WENG J X, LI W W, et al. Spatial-temporal varying coefficient model for lane-changing behavior in work zone merging areas [J]. Journal of Transportation Safety & Security, 2022, 14 (6): 949-972.

中国知网 https://www.cnki.net

[8] LI Y, WU D, LEE J, et al. Analysis of the transition condition of rear-end collisions using time-to-collision index and vehicle trajectory data [J]. Accident Analysis & Prevention, 2020, 144: 105676-105676.

[9] PARK H, OH C, MOON J, et al. Development of a lane change risk index using vehicle trajectory data [J]. Accident Analysis & Prevention, 2018, 110: 1-8.

[10] ZHANG Y, ZOU Y J, Selpi, et al. Spatiotemporal interaction pattern recognition and risk evolution analysis during lane changes [J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24 (6): 6663-6673.

[11] 王慧然，陈无畏，王其东，等. 基于相邻车道安全态势划分的换道决策[J]. 机械工程学报，2023，59(2)：233-244.
WANG Hui-ran, CHEN Wu-wei, WANG Qi-dong, et al. Lane change decision based on the safety state division of the adjacent lanes [J]. Journal of Mechanical Engineering, 2023, 59 (2): 233-244.

[12] 谢济铭，彭　博，秦雅琴. 基于换道概率分布的多车道交织区元胞自动机模型[J]. 交通运输系统工程与信息，2022，22(3)：276-285.
XIE Ji-ming, PENG Bo, QIN Ya-qin. Cellular automata model of multi-lane weaving area based on lane-changing probability distribution [J]. Journal of Transportation Systems Engineering and Information Technology, 2022, 22 (3): 276-285.

[13] 严永俊，彭　林，王金湘，等. 混驾环境下基于主从博弈的多车协同决策规划[J]. 中国公路学报，2024，37(3)：117-133.
YAN Yong-jun, PENG Lin, WANG Jin-xiang, et al. Multi-vehicle cooperative decision-making and trajectory planning based on stackelberg game theory in mixed driving environments [J]. China Journal of Highway and Transport, 2024, 37 (3): 117-133.

[14] WANG S, FUJII H, YOSHIMURA S. Generating merging strategies for connected autonomous vehicles based on spatio-temporal information extraction module and deep reinforcement learning [J]. Physica A: Statistical Mechanics and Its Applications, 2022, 607: 128172.

[15] AMMOURAH R, TALEBPOUR A. Deep reinforcement learning approach for automated vehicle mandatory lane changing [J]. Transportation Research Record: Journal of the Transportation Research Board, 2023 (2677): 712-724.

[16] HUANG Y J, DING H T, ZHANG Y B, et al. A motion planning and tracking framework for autonomous vehicles based on artificial potential field elaborated resistance network approach [J]. IEEE Transactions on Industrial Electronics, 2020, 67 (2): 1376-1386.

[17] 冯付勇，魏　超，吕彦直，等. 基于 GCN 和 QP 的智能车辆换道决策规划[J]. 北京理工大学学报，2024，44(8)：820-827.
FENG Fu-yong, WEI Chao, LÜ Yan-zhi, et al. Lane change decision making and planning of intelligent vehicles based on GCN and QP [J]. Transactions of Beijing Institute of Technology, 2024, 44 (8): 820-827.

[18] GLASER S, VANHOLME B, MAMMAR S, et al. Maneuver-based trajectory planning for highly autonomous vehicles on real road with traffic and driver interaction [J]. IEEE Transactions on Intelligent Transportation Systems, 2010, 11 (3): 589-606.

[19] WANG H, HUANG Y J, KHAJEPOUR A, et al. Crash mitigation in motion planning for autonomous vehicles [J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 20 (9): 3313-3323.

[20] KIM J H, KUM D S. Threat prediction algorithm based on local path candidates and surrounding vehicle trajectory predictions for automated driving vehicles [C] // IEEE. 2015 IEEE Intelligent Vehicles Symposium (IV). New York: IEEE, 2015: 1220-1225.

[21] SHEN Y, PENG J K, KANG C, et al. Collaborative optimisation of lane change decision and trajectory based on double-layer deep reinforcement learning [J]. International Journal of Vehicle Design, 2023, 92 (2/3/4): 336-356.

[22] 蔺庆海，何兆成，谢　俊，等. 基于 AVI 数据与深度强化学习的城市快速路匝道协调控制方法[J]. 中国公路学报，2023，36(10)：224-237.
LIN Qing-hai, HE Zhao-cheng, XIE Jun, et al. Urban expressway coordinated ramp metering approach using automatic vehicle identification data and deep reinforcement learning [J]. China Journal of Highway and Transport, 2023, 36 (10): 224-237.

[23] 谷梦路，葛振振，王　畅，等. 智能网联车辆加速车道类人化汇入控制研究[J]. 中国公路学报，2024，37(3)：134-146.
GU Meng-lu, GE Zhen-zhen, WANG Chang, et al. Human-like merging control of intelligent connected vehicles on the acceleration lane [J]. China Journal of Highway and Transport, 2024, 37 (3): 134-146.

[24] 罗　鹏，黄　珍，秦易晋，等. 基于 DQN 的车辆驾驶行为决策方法[J]. 交通信息与安全，2020，38(5)：67-77，112.
LUO Peng, HUANG Zhen, QIN Yi-jin, et al. Decision method of vehicle driving behavior based on DQN [J]. Journal of Transport Information and Safety, 2020, 38 (5): 67-77, 112.

[25] BENCE D, GERGÖ L, GERGELY H. Highway situation analysis with scenario classification and neural network based risk estimation for autonomous vehicles [C] // IEEE. 2019 IEEE 17th World Symposium on Applied Machine Intelligence and Informatics (SAMI). New York: IEEE, 2019: 375-380.

[26] LI G F, YANG Y F, LI S, et al. Decision making of autonomous vehicles in lane change scenarios: Deep reinforcement learning approaches with risk awareness [J]. Transportation Research Part C: Emerging Technologies, 2022, 134: 103452.

[27] MNIH V, KAVUKCUOGLU K, SILVER D, et al. Human-level control through deep reinforcement learning [J]. Nature, 2015, 518 (7540): 529-533.

中国知网　https://www.cnki.net

[28] VAN HASSELT H, GUEZ A, SILVER D. Deep reinforcement learning with double Q-learning [J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2016, 30 (1): 2094-2100.

[29] WANG Z Y, SCHAUL T, HESSEL M, et al. Dueling network architectures for deep reinforcement learning [C] // ICML. 33rd International Conference on Machine Learning. New York: ICML, 2016: 2939-2947.

[30] LI G, QIU Y, YANG Y, et al. Lane change strategies for autonomous vehicles: A deep reinforcement learning approach based on transformer [J]. IEEE Transactions on Intelligent Vehicles, 2022, 8 (3): 2197-2211.

[31] 程国柱,孟凤威,徐 亮.城市快速路合流区智能网联车辆换道风险实时评估方法[J/OL].吉林大学学报(工学版),(2024-09-24)[2024-09-25]. https://doi.org/10.13229/j.cnki.jdxbgxb.20240632.

CHENG Guo-zhu, MENG Fei-wei, XU Liang. Real-time risk assessment method for connected autonomous vehicle lane changing on urban express-ways. [J/OL]. Journal of Jilin University (Engineering and Technology Edition), (2024-09-24) [2024-09-25]. https://doi.org/10.13229/j.cnki.jdxbgxb.20240632.

[32] 杨小宝,张 宁.任意性换道模型的比较与选择[J].交通运输系统工程与信息,2006(4):53-56.

YANG Xiao-bao, ZHANG Ning. Comparison and choice of discretionary lane-changing models [J]. Journal of Transportation Systems Engineering and Information Technology, 2006 (4): 53-56.

[33] KESTING A, TREIBER M, HELBING D. Enhanced intelligent driver model to access the impact of driving strategies on traffic capacity [J]. Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences, 2010, 368 (1928): 4585-4605.

[34] KESTING A, TREIBER M, HELBING D. General lane-changing model MOBIL for car-following models [J]. Transportation Research Record: Journal of the Transportation Research Board, 2007 (1999): 86-94.

[35] 李伟东,马草原,史 浩,等.基于分层强化学习的自动驾驶决策控制算法[J/OL].吉林大学学报(工学版),(2023-12-19)[2024-01-09]. https://doi.org/10.13229/j.cnki.jdxbgxb.20230891.

LI Wei-dong, MA Cao-yuan, SHI Hao, et al. An automatic driving decision control algorithm based on hierarchical reinforcement learning [J/OL]. Journal of Jilin University (Engineering and Technology Edition), (2023-12-19) [2024-01-09]. https://doi.org/10.13229/j.cnki.jdxbgxb.20230891.

[36] 刘卫国,项志宇,刘伟平,等.基于分布式强化学习的车辆控制算法研究[J].汽车工程,2023,45(9):1637-1645.

LIU Wei-guo, XIANG Zhi-yu, LIU Wei-ping, et al. Research on vehicle control algorithm based on distributed reinforcement learning [J]. Automotive Engineering, 2023, 45 (9): 1637-1645.

[37] XU J, YANG K, SHAO Y M, et al. An experimental study on lateral acceleration of cars in different environments in Sichuan, Southwest China [J]. Discrete Dynamics in Nature and Society, 2015, 2015: 494130.

中国知网 https://www.cnki.net